



เอกสารประกอบการเสนอหัวข้อโครงการปริญญานิพนธ์
สาขาภาควิชาชีวการแพทย์และสารสนเทศศาสตร์ทางสุขภาพคณะเภสัชศาสตร์
มหาวิทยาลัยศิลปากร
ภาคการศึกษาปลาย ปีการศึกษา 2567

1. รหัสโครงการปริญญานิพนธ์

-

2. ชื่อหัวข้อโครงการปริญญานิพนธ์

การจำแนกใบสั่งยาแบบหลายป้ายกำกับด้วย Knowledge Base Generative AI
Prescription Multi-label Classification with Knowledge Base Generative AI

3. ผู้รับผิดชอบโครงการฯ

ภก.ศิวารุธ มงคล

รหัสนักศึกษา 660820006

4. อาจารย์ที่ปรึกษาโครงการ

รองศาสตราจารย์ ดร. ภก.วีรยุทธ เลิศนที

สารบัญ

บทที่ 1	6
บทนำ	6
ความเป็นมาและความสำคัญของปัญหา	6
ความคลาดเคลื่อนทางยา (Medication Errors)	6
ผลกระทบจากความคลาดเคลื่อนทางยา (Medication Errors)	7
การประยุกต์ใช้ Knowledge-Based Generative AI ในการจัดการความคลาดเคลื่อนทางยา	8
วัตถุประสงค์ของการวิจัย	9
สมมติฐานของการวิจัย	10
ขอบเขตของการวิจัย	10
กรอบแนวคิดในการวิจัย	10
ประโยชน์ที่ได้รับ	11
นิยามศัพท์เฉพาะ	11
บทที่ 2	14
วรรณกรรมที่เกี่ยวข้อง	14
ความปลอดภัยทางยาและความคลาดเคลื่อนทางยาในระบบสาธารณสุข	14
แนวคิดและนิยามของความคลาดเคลื่อนทางยา (Medication Errors)	14
ประเภทของความคลาดเคลื่อนทางยา โดยเน้นข้อผิดพลาดในการสั่งจ่ายยา (Prescription Errors)	15
ปัจจัยเสี่ยงและบริบทที่นำไปสู่ความคลาดเคลื่อนทางยา	15
ผลกระทบของความคลาดเคลื่อนทางยาต่อผู้ป่วย บุคลากร และระบบสุขภาพ	16
ระบบสนับสนุนการตัดสินใจทางคลินิก (Clinical Decision Support Systems; CDSS)	17
แนวคิดและบทบาทของระบบสนับสนุนการตัดสินใจทางคลินิก	17
CDSS สำหรับการสั่งจ่ายยาและความปลอดภัยทางยา	17
ข้อจำกัดของ CDSS แบบดั้งเดิม	18
บทบาทของ CDSS ในการพัฒนาไปสู่ระบบ AI	18
เทคโนโลยีปัญญาประดิษฐ์ในระบบสาธารณสุข	19
แนวคิดพื้นฐานของปัญญาประดิษฐ์ในทางการแพทย์	19
Machine Learning และ Deep Learning ในงานด้านสาธารณสุข	19
การประมวลผลภาษาธรรมชาติ (Natural Language Processing; NLP) กับข้อมูลทางการแพทย์	20
ข้อจำกัดและความท้าทายของ AI ในระบบสาธารณสุข	21
การพัฒนา AI จากระบบวิเคราะห์ข้อมูลสู่ Generative AI	21
การใช้ปัญญาประดิษฐ์เพื่อตรวจสอบและจำแนกใบสั่งยา	22
การประยุกต์ใช้ Machine Learning ในการตรวจจับความคลาดเคลื่อนทางยา	22
การประเมินประสิทธิภาพของโมเดล AI ในการจำแนกใบสั่งยา	22
การใช้ AI ร่วมกับ CDSS เพื่อลด Alert Fatigue และเพิ่มความแม่นยำ	23
ข้อจำกัดของการใช้ AI แบบ Data-Driven ในการตรวจสอบใบสั่งยา	23
ความจำเป็นของแนวทาง Knowledge-Based AI ในการจำแนกใบสั่งยา	24

เทคโนโลยีปัญญาประดิษฐ์และฐานความรู้ในระบบสาธารณสุข	24
ระบบฐานความรู้ (Knowledge-Based Systems) ในการแพทย์และเภสัชกรรม	25
แนวคิดและโครงสร้างของระบบฐานความรู้ (Knowledge-Based Systems)	25
ฐานความรู้ทางคลินิกและเภสัชกรรม	26
Knowledge Graph และการเชื่อมโยงข้อมูลทางการแพทย์	26
บทบาทของ Knowledge-Based Systems ในการสนับสนุนการตัดสินใจทางคลินิก	27
จาก Knowledge-Based Systems สู่ Knowledge-Based Generative AI	27
แนวคิดและหลักการของ Generative AI ในงานด้านสาธารณสุข	28
แนวคิดพื้นฐานของ Generative AI และ Large Language Models	28
การประยุกต์ใช้ Generative AI ในระบบสาธารณสุข	28
ข้อจำกัดของ Generative AI ในบริบททางคลินิก	29
แนวทางการเพิ่มความน่าเชื่อถือของ Generative AI ด้วยฐานความรู้	30
บทบาทของ Generative AI ต่อการพัฒนา Knowledge-Based Generative AI	30
การใช้ Knowledge-Based Generative AI ในการตรวจสอบใบสั่งยา	30
แนวคิดของ Knowledge-Based Generative AI ในบริบททางคลินิก	30
การผสานฐานความรู้กับ Generative AI เพื่อเพิ่มความถูกต้องและความน่าเชื่อถือ	31
การประยุกต์ใช้ Knowledge-Based AI ในการตรวจสอบความปลอดภัยของยา	31
ข้อได้เปรียบของ Knowledge-Based Generative AI เหนือแนวทางเดิม	32
ข้อจำกัดและช่องว่างของงานวิจัยที่เกี่ยวข้อง	32
ปัญหาภาวะหลอน (Hallucination) และความน่าเชื่อถือของ Generative AI	33
ความหมายและลักษณะของภาวะหลอนของปัญญาประดิษฐ์ (AI Hallucination)	33
รูปแบบของภาวะหลอนและผลกระทบต่องานเชิงวิชาการและคลินิก	33
ความลำเอียงของข้อมูล (Bias) และผลต่อความน่าเชื่อถือของ AI	34
แนวทางการลดความเสี่ยงจาก Hallucination ในงานด้านการแพทย์	34
ความสำคัญของความน่าเชื่อถือและการกำกับดูแลในการใช้ Generative AI	34
ประเภทของโมเดลการจำแนกข้อมูล: Binary, Multiclass และ Multilabel Classification	35
Binary Classification	35
Multiclass Classification	35
Multilabel Classification	36
ความสำคัญของรูปแบบการจำแนกต่อการวิเคราะห์ใบสั่งยา	36
สรุปวรรณกรรมและช่องว่างของงานวิจัย (Research Gap)	36
บทที่ 3	40
วิธีดำเนินการวิจัย	40
ประชากรและกลุ่มตัวอย่าง	40
ประชากรในการวิจัย	40
กลุ่มตัวอย่าง	40
เกณฑ์การคัดเข้า	40
เกณฑ์การคัดออก	41
ผู้เข้าร่วมการทดลอง	41
เครื่องมือที่ใช้ในการเก็บรวบรวมข้อมูล	41
1. Knowledge-Based Generative AI System (KBGI)	41
2. Electronic Health Records (EHRs)	41
การสร้างเครื่องมือที่ใช้ในการเก็บรวบรวมข้อมูล	42

1. การพัฒนา Knowledge-Based Generative AI System (KBGI)	42
1.1 การรวบรวมฐานความรู้ (Knowledge Base Construction)	42
1.2 การออกแบบระบบปัญญาประดิษฐ์ (AI System Design)	43
1.3 การทดสอบระบบ (System Testing)	44
2. การพัฒนาโปรแกรมวิเคราะห์ผลลัพธ์ด้วยภาษา Python	45
1. การจัดการและทำความสะอาดข้อมูล (Data Cleaning)	45
2. การเตรียมข้อมูลสำหรับการจำแนกแบบหลายป้ายกำกับ (Multi-label Classification)	46
3. การสร้าง data pipeline สำหรับส่งข้อมูลเข้าสู่ ChatGPT / KBGI	46
4. การเชื่อมต่อ API และการจัดการผลลัพธ์จากโมเดล	47
5. การคำนวณตัวชี้วัดทางสถิติและการสร้างรายงานผล	47
6. สภาพแวดล้อมในการพัฒนาและรันโปรแกรม (Execution Environment)	47
การเก็บรวบรวมข้อมูล	48
ข้อมูลที่ใช้ในการวิเคราะห์	48
ข้อมูลผู้ป่วย	48
ข้อมูลใบสั่งยา	48
ผลลัพธ์จากระบบ AI	49
การวิเคราะห์ข้อมูลและสถิติที่ใช้ในการวิเคราะห์ข้อมูล	49
บรรณานุกรม	52

บทที่ 1

บทนำ

ความเป็นมาและความสำคัญของปัญหา

ความคลาดเคลื่อนทางยา (Medication Errors)

ความคลาดเคลื่อนทางยา (Medication Errors) หมายถึง เหตุการณ์หรือการกระทำที่สามารถป้องกันได้ ซึ่งนำไปสู่หรือมีศักยภาพที่จะนำไปสู่การใช้ยาที่ไม่เหมาะสมหรือก่อให้เกิดอันตรายต่อผู้ป่วย อันเป็นผลจากความล้มเหลวของกระบวนการที่เกี่ยวข้องกับการใช้ยาในระบบบริการสุขภาพ ความคลาดเคลื่อนดังกล่าวสามารถเกิดขึ้นได้ตลอดวงจรการใช้ยา (medication use process) ตั้งแต่ขั้นตอนการสั่งจ่ายยา การทบทวนใบสั่งยา การจ่ายยา การบริหารยา ไปจนถึงการติดตามผลการรักษา (Alsulami et al., 2013; Corny et al., 2020)

ในเชิงระบบ ความคลาดเคลื่อนทางยาไม่เพียงสะท้อนถึงความผิดพลาดของบุคลากรทางการแพทย์รายบุคคลเท่านั้น หากแต่เป็นผลลัพธ์จากความซับซ้อนของกระบวนการทำงาน การสื่อสารที่ไม่สมบูรณ์ ข้อจำกัดด้านเวลา ภาระงานที่สูง รวมถึงข้อจำกัดของระบบสารสนเทศทางสุขภาพที่ยังไม่สามารถสนับสนุนการตัดสินใจได้อย่างครอบคลุม ความคลาดเคลื่อนทางยาจึงถูกยอมรับในระดับสากลว่าเป็นหนึ่งในปัญหาหลักด้านความปลอดภัยของผู้ป่วย (patient safety) และเป็นสาเหตุสำคัญของเหตุการณ์ไม่พึงประสงค์จากยา (Adverse Drug Events; ADEs) ซึ่งส่งผลกระทบต่อผลลัพธ์ทางคลินิก คุณภาพชีวิตของผู้ป่วย และต้นทุนด้านสาธารณสุข (Alsulami et al., 2013; Natsiavas et al., 2019)

ในบรรดาความคลาดเคลื่อนทางยาทั้งหมด ข้อผิดพลาดในการสั่งจ่ายยา (Prescription Errors) ถือเป็นจุดเริ่มต้นที่มีความสำคัญอย่างยิ่ง เนื่องจากเป็นต้นทางของกระบวนการใช้ยาและมีอิทธิพลโดยตรงต่อขั้นตอนถัดไป ความผิดพลาดในระยษนี้มักเกี่ยวข้องกับการเลือกยาที่ไม่เหมาะสมกับข้อบ่งใช้ การกำหนดขนาดยาไม่สอดคล้องกับลักษณะผู้ป่วย การสั่งยาที่มีปฏิกิริยาระหว่างกัน หรือการขาดข้อมูลสำคัญ เช่น ประวัติการแพ้ยาและภาวะโรคร่วมของผู้ป่วย ปัญหาเหล่านี้พบได้อย่างต่อเนื่องทั้งในประเทศที่มีทรัพยากรด้านสาธารณสุขสูงและประเทศกำลังพัฒนา สะท้อนให้เห็นถึงข้อจำกัดของระบบการตรวจสอบแบบดั้งเดิมที่ยังอาศัยแรงงานมนุษย์เป็นหลัก (Härkänen et al., 2021; Kuperman et al., 2007)

จากบริบทดังกล่าว การพัฒนาเครื่องมือที่สามารถสนับสนุนการตรวจสอบใบสั่งยาได้อย่างเป็นระบบ แม่นยำ และสอดคล้องกับบริบททางคลินิก จึงเป็นประเด็นสำคัญของการวิจัยด้านเภสัชสารสนเทศและความปลอดภัยทางยาในปัจจุบัน (Sutton et al., 2020)

ผลกระทบจากความคลาดเคลื่อนทางยา (Medication Errors)

ความคลาดเคลื่อนทางยาเป็นปัญหาที่มีความสำคัญอย่างยิ่งต่อระบบบริการสุขภาพ เนื่องจากส่งผลกระทบในหลายมิติ ทั้งในระดับผู้ป่วย บุคลากรทางการแพทย์ สถานพยาบาล และระบบสาธารณสุขโดยรวม แม้ว่าความคลาดเคลื่อนทางยาจำนวนหนึ่งอาจไม่ก่อให้เกิดอันตรายรุนแรงในทันที แต่เหตุการณ์ดังกล่าวสะท้อนถึงความเปราะบางของกระบวนการใช้ยา และมีศักยภาพที่จะพัฒนาไปสู่เหตุการณ์ไม่พึงประสงค์จากยา (Adverse Drug Events; ADEs) ซึ่งสามารถป้องกันได้ (Alsulami et al., 2013)

ในระดับผู้ป่วย ความคลาดเคลื่อนทางยาสามารถนำไปสู่อาการไม่พึงประสงค์จากยา (Adverse Drug Reactions; ADRs) ภาวะแทรกซ้อนทางคลินิก การยืดระยะเวลาการรักษาในโรงพยาบาล และในบางกรณีอาจก่อให้เกิดอันตรายรุนแรงถึง

ชั้นเสียชีวิต โดยเฉพาะในกลุ่มผู้ป่วยที่มีความเสี่ยงสูง เช่น ผู้สูงอายุ ผู้ป่วยโรคเรื้อรัง ผู้ป่วยที่ได้รับยาหลายชนิดร่วมกัน (polypharmacy) และผู้ป่วยที่มีภาวะการทำงานของอวัยวะบกพร่อง ความคลาดเคลื่อนทางยาในกลุ่มนี้มักมีความซับซ้อน และยากต่อการตรวจจับด้วยการตรวจสอบแบบดั้งเดิม (Gonzaga De Andrade Santos et al., 2020)

ในระดับบุคลากรทางการแพทย์ ความคลาดเคลื่อนทางยาเป็นแหล่งก่อให้เกิดภาระทางจิตใจ ความเครียดจากการทำงาน และความกังวลด้านความรับผิดชอบทางวิชาชีพ โดยเฉพาะในบริบทของสถานพยาบาลที่มีภาระงานสูงและข้อจำกัดด้านเวลา ระบบที่พึ่งพาการตรวจสอบโดยมนุษย์เพียงอย่างเดียวอาจไม่สามารถรองรับปริมาณข้อมูลและความซับซ้อนของใบสั่งยาในปัจจุบันได้อย่างมีประสิทธิภาพ ซึ่งเพิ่มโอกาสการเกิด human error โดยไม่เจตนา (Kuperman et al., 2007)

ในระดับองค์กรและระบบสาธารณสุข ความคลาดเคลื่อนทางยาส่งผลให้ต้นทุนการรักษาเพิ่มสูงขึ้น ทั้งจากค่าใช้จ่ายในการรักษาภาวะแทรกซ้อน การกลับเข้ารับรักษาซ้ำในโรงพยาบาล และการใช้ทรัพยากรทางการแพทย์ที่เกินความจำเป็น นอกจากนี้ยังส่งผลกระทบต่อคุณภาพการให้บริการ ความเชื่อมั่นของผู้ป่วย และภาพลักษณ์ของสถานพยาบาลในระยะยาว จากมุมมองเชิงนโยบาย ความคลาดเคลื่อนทางยาจึงถูกจัดให้เป็นปัญหาที่สามารถป้องกันได้ (preventable harm) และเป็นหนึ่งในตัวชี้วัดสำคัญด้านความปลอดภัยของผู้ป่วยใน ระบบสุขภาพสมัยใหม่ (Natsiavas et al., 2019)

เมื่อพิจารณาถึงความสำคัญและผลกระทบดังกล่าว การพัฒนาเครื่องมือและระบบสนับสนุนที่สามารถช่วยตรวจจับ ป้องกัน และจัดการความคลาดเคลื่อนทาง ยาได้อย่างเป็นระบบจึงมีความจำเป็นอย่างยิ่ง โดยเฉพาะเครื่องมือที่สามารถประมวลผลข้อมูลจำนวนมาก วิเคราะห์บริบททางคลินิกที่ซับซ้อน และสนับสนุนการตัดสินใจของบุคลากรทางการแพทย์ได้อย่างแม่นยำ ซึ่งเป็นเหตุผลสำคัญที่นำไปสู่การประยุกต์ใช้เทคโนโลยีปัญญาประดิษฐ์ และโดยเฉพาะ Knowledge-Based Generative AI ในการยกระดับความปลอดภัยทางยาในงานวิจัยนี้ (Noorbakhsh-Sabet et al., 2019; Rajkomar et al., 2019)

ในทางปฏิบัติ ใบสั่งยาหนึ่งใบอาจพบความคลาดเคลื่อนมากกว่าหนึ่งประเภทได้พร้อมกัน เช่น การสั่งขนาดยาไม่เหมาะสมร่วมกับการเกิดปฏิกิริยาระหว่างยา ดังนั้น การจำแนกใบสั่งยาแบบให้มีเพียง 1 ประเภท หรือการระบุเพียงว่ามีหรือไม่มีข้อผิดพลาด อาจไม่สะท้อนความซับซ้อนของสถานการณ์จริงทางคลินิกได้อย่างเพียงพอ

ด้วยเหตุนี้ แนวคิดการจำแนกแบบหลายป้ายกำกับ (Multi-label Classification) จึงถูกนำมาใช้ เพื่อให้ระบบสามารถระบุความคลาดเคลื่อนหลายประเภทในใบสั่งยาเดียวได้พร้อมกัน ซึ่งสอดคล้องกับการปฏิบัติงานของเภสัชกรใน สถานการณ์จริงมากขึ้น

การประยุกต์ใช้ Knowledge-Based Generative AI ในการจัดการความคลาดเคลื่อนทางยา

ความก้าวหน้าของเทคโนโลยีปัญญาประดิษฐ์ (Artificial Intelligence; AI) ได้เปิดโอกาสใหม่ในการยกระดับกระบวนการจัดการความคลาดเคลื่อนทางยา โดยเฉพาะในบริบทของการวิเคราะห์ใบสั่งยาที่มีความซับซ้อนสูง แนวทางการใช้ AI ในระยะแรกมักอยู่ในรูปของระบบฐานกฎ (Rule-Based Systems) ซึ่งอาศัยตรรกะและกฎที่กำหนดไว้ล่วงหน้าในการตรวจสอบความไม่สอดคล้องของข้อมูลยา อย่างไรก็ตาม ระบบลักษณะดังกล่าวมีข้อจำกัดด้านความยืดหยุ่น ไม่สามารถปรับตัวได้ดีต่อแนวทางการรักษาที่เปลี่ยนแปลงอย่างรวดเร็ว และต้องอาศัยการบำรุงรักษาฐานกฎอย่างต่อเนื่อง (Sutton et al., 2020)

ต่อมา การประยุกต์ใช้ Machine Learning และ Deep Learning ได้เข้ามามีบทบาทสำคัญ โดยโมเดลสามารถเรียนรู้รูปแบบของข้อผิดพลาดจากข้อมูลใบสั่งยาและข้อมูลผู้ป่วยจำนวนมาก ช่วยคัดแยกใบสั่งยาที่มีความเสี่ยงสูงได้อย่างมีประสิทธิภาพ งานวิจัยของ Corny และคณะ แสดงให้เห็นว่าโมเดล machine learning สามารถช่วยคัดกรองใบสั่งยาที่มีความเสี่ยงต่อ medication error ได้ดีกว่าระบบแบบดั้งเดิม (Corny et al., 2020)

อย่างไรก็ตาม โมเดลที่อาศัยการเรียนรู้จากข้อมูลเพียงอย่างเดียว (data-driven models) ยังคงมีข้อจำกัดด้านความสามารถในการอธิบายผลลัพธ์ (explainability) และอาจให้ผลลัพธ์ที่ไม่สอดคล้องกับหลักการทางคลินิกในบางสถานการณ์ ซึ่งเป็นข้อจำกัดสำคัญในการนำไปใช้จริงในระบบบริการสุขภาพ (Rajkomar et al., 2019)

Knowledge-Based Generative AI จึงถูกพัฒนาขึ้นเพื่อเชื่อมช่องว่างดังกล่าว โดยเป็นการบูรณาการความสามารถของ Generative AI ในการประมวลผลภาษาและสร้างเหตุผลเชิงบริบท เข้ากับฐานความรู้ทางการแพทย์และเภสัชกรรมที่ผ่านการตรวจสอบแล้ว เช่น แนวทางการรักษา ข้อมูลข้อบ่งใช้ยา ข้อห้ามใช้ ปฏิกริยาระหว่างยา และหลักการปรับขนาดยาตามลักษณะผู้ป่วย ระบบในลักษณะนี้ไม่เพียงสามารถจำแนกใบสั่งยาตามระดับความเสี่ยงหรือประเภทของข้อผิดพลาดได้เท่านั้น แต่ยังสามารถอธิบายเหตุผลของการตัดสินใจในเชิงตรรกะทางคลินิก ซึ่งมีความสำคัญอย่างยิ่งต่อการยอมรับของบุคลากรทางการแพทย์ (Lan et al., 2021; Luo et al., 2024)

ในบริบทของการจัดการความคลาดเคลื่อนทางยา Knowledge-Based Generative AI มีศักยภาพในการวิเคราะห์ใบสั่งยาที่มีข้อมูลหลากหลายมิติ ทั้งข้อมูลผู้ป่วย ข้อมูลการวินิจฉัย และข้อมูลยาแบบไม่เป็นโครงสร้าง (unstructured data) พร้อมทั้งเชื่อมโยงข้อมูลเหล่านั้นเข้ากับองค์ความรู้ทางคลินิกที่เกี่ยวข้อง ส่งผลให้สามารถตรวจจับความผิดพลาดเชิงซับซ้อนที่ระบบแบบดั้งเดิมอาจมองข้ามได้ นอกจากนี้ การออกแบบระบบให้ทำงานร่วมกับเภสัชกรในลักษณะ “decision support” มากกว่าการตัดสินใจแทน ยังช่วยลดความเสี่ยงจากการพึ่งพา AI มากเกินไป และเพิ่มความปลอดภัยในการนำไปใช้จริงในระบบบริการสุขภาพ (Crossnohere et al., 2022; Mesko & Topol, 2023a)

ดังนั้น การประยุกต์ใช้ Knowledge-Based Generative AI เพื่อจำแนกและจัดการความคลาดเคลื่อนทางยา จึงถือเป็นแนวทางที่มีความทันสมัยและมีศักยภาพสูงในการยกระดับความปลอดภัยทางยา ตลอดจนเป็นกรอบการวิจัยที่สอดคล้องกับทิศทางการพัฒนาระบบสุขภาพอัจฉริยะในอนาคต

วัตถุประสงค์ของการวิจัย

1. เพื่อพัฒนาระบบ Knowledge Base Generative AI สำหรับการจำแนกประเภทความคลาดเคลื่อนของใบสั่งยาแบบหลายป้ายกำกับ (Multi-label Classification)
2. เพื่อประเมินประสิทธิภาพของระบบ Knowledge Base Generative AI ในการตรวจจับและจำแนกความคลาดเคลื่อนของใบสั่งยาหลายประเภทที่อาจเกิดร่วมกันในใบสั่งยาเดียว
3. เพื่อศึกษาความสอดคล้องระหว่างผลการจำแนกของระบบ AI กับการประเมินของเภสัชกร และวิเคราะห์แนวทางการปรับปรุงความแม่นยำของระบบ

สมมติฐานของการวิจัย


ระบบ Knowledge Base Generative AI จะสามารถตรวจจับและจำแนกความคลาดเคลื่อนของใบสั่งยาแบบหลายป้ายกำกับได้อย่างถูกต้อง และมีความสอดคล้องกับการประเมินของเภสัชกรในระดับที่ยอมรับได้

ขอบเขตของการวิจัย

การวิจัยนี้จะดำเนินการเป็นระยะเวลา 12 เดือน ตั้งแต่วันที่ 1 มีนาคม พ.ศ.2568 - 28 กุมภาพันธ์ พ.ศ.2569 โดยทำการเก็บข้อมูลย้อนหลัง (Retrospective) เกี่ยวกับการใช้งาน Knowledge Base Generative AI เพื่อจำแนกประเภทการสั่งจ่ายยาและตรวจสอบข้อผิดพลาดในการสั่งจ่ายยา ซึ่งจะดำเนินการในโรงพยาบาลกรุงเทพขอนแก่น และมีการทดลองใช้งานโดย เภสัชกรวิชาชีพ ในโรงพยาบาล การศึกษานี้จะครอบคลุมการสั่งจ่ายยาทุกรายการของโรงพยาบาล และจะประเมินผลลัพธ์โดยใช้ข้อมูลจากระบบเวชระเบียนอิเล็กทรอนิกส์ (EHR) เพื่อตรวจสอบประสิทธิภาพของ AI ในการลดข้อผิดพลาดในการสั่งจ่ายยาและเพิ่มความปลอดภัยให้กับผู้ป่วย

กรอบแนวคิดในการวิจัย

การวิจัยครั้งนี้มีวัตถุประสงค์เพื่อพัฒนาและประเมินประสิทธิภาพของ Knowledge-Based Generative AI System (KBGI) สำหรับการจำแนกประเภทใบสั่งยาและตรวจจับความคลาดเคลื่อนทางยา โดยอาศัยแนวคิดการผสมผสานระหว่าง Generative AI และ ฐานความรู้ทางคลินิกด้านเภสัชกรรม เพื่อสนับสนุนการตัดสินใจของเภสัชกรในการตรวจสอบความปลอดภัยของการสั่งจ่ายยา



ประโยชน์ที่ได้รับ

งานวิจัยนี้มุ่งเน้นไปที่การสำรวจความสามารถของ Knowledge Base Generative AI ในการ จำแนกประเภทการสั่งจ่ายยาและป้องกันข้อผิดพลาด เพื่อช่วยให้ระบบสาธารณสุขมีความปลอดภัยและมีประสิทธิภาพมากขึ้น

นิยามศัพท์เฉพาะ

1. Medication Error (ข้อผิดพลาดด้านยา)

หมายถึง เหตุการณ์ที่สามารถป้องกันได้ ซึ่งอาจเป็นสาเหตุหรือนำไปสู่การใช้ยาที่ไม่เหมาะสมหรือเป็นอันตรายต่อผู้ป่วย ขณะที่ยาอยู่ในการควบคุมของบุคลากรวิชาชีพด้านสุขภาพ ผู้ป่วย หรือผู้บริโภครวมถึงเหตุการณ์เหล่านี้ อาจเกี่ยวข้องกับการปฏิบัติทางวิชาชีพ ผลลัพธ์สุขภาพ วิธีการปฏิบัติ และระบบที่ครอบคลุมการสั่งจ่ายยา การสื่อสาร คำสั่ง การจัดทำฉลากยา/การบรรจุและการตั้งชื่อผลิตภัณฑ์ การเตรียมยา การจ่ายยา การกระจายยา การให้ยา การให้ความรู้ การติดตาม และการใช้ยา

2. Prescription Error (ข้อผิดพลาดในการสั่งจ่ายยา)

คือ ความคลาดเคลื่อนในการสั่งจ่ายยาของแพทย์ เช่น การเลือกยาที่ไม่เหมาะสมตามข้อบ่งใช้ ข้อห้ามใช้ การสั่งยาซ้ำซ้อน การสั่งยาที่มีปฏิกิริยาต่อกัน การสั่งจ่ายยาที่ผู้ป่วยมีประวัติแพ้ รวมถึงความไม่สมบูรณ์ในการสั่งจ่ายยา หรือความคลาดเคลื่อนเรื่องความแรง รูปแบบของยา ปริมาณหรือรายการ วิธีใช้ยา ความเข้มข้น อัตราเร็วในการให้ยา ซึ่งล้วนนำไปสู่การเกิดความผิดพลาดในการให้ยาแก่ผู้ป่วยได้

3. Generative AI (ปัญญาประดิษฐ์เชิงสร้างสรรค์)

เทคโนโลยีที่ใช้แบบจำลองปัญญาประดิษฐ์เพื่อสร้างข้อมูลใหม่จากฐานข้อมูลที่มีอยู่ โดยใช้โมเดลที่สามารถเรียนรู้จากตัวอย่างข้อมูลเดิมและพัฒนาแนวทางใหม่ในการแก้ปัญหา

4. Knowledge Base (ฐานความรู้)

ระบบที่รวบรวมข้อมูล ข้อเท็จจริง และกฎเกณฑ์ที่ใช้เป็นแหล่งอ้างอิงสำหรับการตัดสินใจ เช่น ฐานข้อมูลทางคลินิกที่ใช้สำหรับสนับสนุนการสั่งจ่ายยา

5. Electronic Health Records (EHRs) (เวชระเบียนอิเล็กทรอนิกส์)

เป็นนวัตกรรมที่ใช้ในการเก็บรวบรวมข้อมูลสารสนเทศด้านสุขภาพอย่างเป็นระบบ ใช้ทดแทนเวชระเบียนในรูปแบบกระดาษ ซึ่งมีความผิดพลาดคลาดเคลื่อนได้มากกว่า โดย EHRs สามารถแบ่งปันข้อมูลระหว่างสถานพยาบาล ถือเป็นแหล่งข้อมูลที่ช่วยในการตัดสินใจของแพทย์พยาบาล ทำให้มีเวลาเพื่อดูแลผู้ป่วยมากขึ้น

6. Drug-Drug Interaction (DDI) (ปฏิกิริยาระหว่างยา)

ผลกระทบที่เกิดขึ้นเมื่อมีการใช้ยามากกว่าหนึ่งชนิดพร้อมกัน โดยอาจส่งผลต่อประสิทธิภาพของยา หรือก่อให้เกิดผลข้างเคียงที่ไม่พึงประสงค์

7. Clinical Decision Support System (CDSS) (ระบบสนับสนุนการตัดสินใจทางคลินิก)

หมายถึง ซอฟต์แวร์คอมพิวเตอร์ที่ออกแบบมาเพื่อช่วยประกอบการตัดสินใจ โดยถูกออกแบบมาเพื่อใช้กับผู้เชี่ยวชาญทางด้านสุขภาพ การทำงานของระบบนี้จะช่วยในการตัดสินใจเกี่ยวกับการดูแลรักษาผู้ป่วย เช่น การแจ้งเตือนข้อผิดพลาดในการสั่งจ่ายยา

8. Adverse Drug Reactions (ADR) (อาการไม่พึงประสงค์จากยา)

ปฏิกิริยาที่เกิดขึ้นจากการใช้ยาในขนาดปกติซึ่งทำให้เกิดอาการข้างเคียงที่ไม่พึงประสงค์ และอาจเป็นอันตรายต่อสุขภาพของผู้ป่วย

9. ฐานความรู้ (Knowledge Base)

แหล่งรวบรวมข้อมูลและองค์ความรู้ที่มีโครงสร้าง เช่น แนวทางการรักษา ข้อมูลยา และหลักเกณฑ์ทางคลินิก ซึ่งใช้สนับสนุนการตัดสินใจของระบบ AI

10. ระบบปัญญาประดิษฐ์เชิงกำเนิดที่มีฐานความรู้ (Knowledge Base Generative AI)

ระบบ Generative AI ที่ถูกเสริมด้วยฐานความรู้ทางคลินิก เช่น แนวทางการใช้ยา หรือข้อมูลปฏิกิริยาระหว่างยา เพื่อเพิ่มความถูกต้องและความน่าเชื่อถือในการวิเคราะห์ข้อมูลทางการแพทย์

11. การจำแนกแบบหลายป้ายกำกับ (Multi-label Classification)

การจำแนกข้อมูลที่อนุญาตให้หนึ่งตัวอย่างสามารถถูกจัดอยู่ในหลายป้ายกำกับ (labels) ได้พร้อมกัน เช่น ใบสั่งยาหนึ่งใบอาจมีความคลาดเคลื่อนหลายประเภทเกิดขึ้นร่วมกัน ได้แก่ การสั่งขนาดยาไม่เหมาะสม การเลือกใช้ยาไม่ตรงข้อบ่งใช้ หรือการเกิดปฏิกิริยาระหว่างยา ซึ่งแตกต่างจากการจำแนกแบบป้ายกำกับเดียว (Single-label Classification) ที่แต่ละตัวอย่างจะถูกจัดให้อยู่ได้เพียงหนึ่งประเภทเท่านั้น

บทที่ 2

วรรณกรรมที่เกี่ยวข้อง

ความปลอดภัยทางยาและความคลาดเคลื่อนทางยาในระบบสาธารณสุข

แนวคิดและนิยามของความคลาดเคลื่อนทางยา (Medication Errors)

ความคลาดเคลื่อนทางยา (Medication Errors) เป็นประเด็นสำคัญด้านความปลอดภัยของผู้ป่วยที่ได้รับการยอมรับในระดับสากลว่าเป็นหนึ่งในสาเหตุหลักของเหตุการณ์ไม่พึงประสงค์ที่สามารถป้องกันได้ในระบบบริการสุขภาพ โดยทั่วไป ความคลาดเคลื่อนทางยาหมายถึงเหตุการณ์หรือการกระทำที่สามารถป้องกันได้ ซึ่งอาจนำไปสู่การใช้ยาที่ไม่เหมาะสมหรือก่อให้เกิดอันตรายต่อผู้ป่วย ในขณะที่ยาอยู่ภายใต้การควบคุมของบุคลากรทางการแพทย์ ผู้ป่วย หรือระบบบริการสุขภาพ (Alsulami et al., 2013; Natsiavas et al., 2019)

ในเชิงระบบ ความคลาดเคลื่อนทางยาไม่ได้สะท้อนเฉพาะความผิดพลาดของบุคลากรทางการแพทย์รายบุคคลเท่านั้น แต่ยังเป็นผลลัพธ์จากความซับซ้อนของกระบวนการใช้ยา การสื่อสารที่ไม่สมบูรณ์ ข้อจำกัดด้านเวลา ภาระงานที่สูง และข้อจำกัดของระบบสารสนเทศทางสุขภาพที่ยังไม่สามารถสนับสนุนการตัดสินใจได้อย่างครอบคลุม จึงทำให้ความคลาดเคลื่อนทางยาถูกจัดเป็นปัญหาหลักด้านความปลอดภัยของผู้ป่วยในระบบบริการสุขภาพสมัยใหม่ (Kuperman et al., 2007; Sutton et al., 2020)

งานวิจัยหลายฉบับชี้ให้เห็นว่า ความคลาดเคลื่อนทางยามักเกิดจากการผสมผสานของปัจจัยด้านมนุษย์ เทคโนโลยี และกระบวนการทำงาน โดยเฉพาะในบริบทของโรงพยาบาลที่มีข้อมูลทางคลินิกจำนวนมากและต้องอาศัยการตัดสินใจอย่างรวดเร็ว Rajkomar และคณะ (2019) อธิบายว่า แม้ระบบสารสนเทศทางสุขภาพจะมีการพัฒนาอย่างมาก แต่การพึ่งพาการประมวลผลข้อมูลของมนุษย์เป็นหลักยังคงเป็นข้อจำกัดสำคัญที่เพิ่มความเสี่ยงของความผิดพลาดโดยไม่เจตนา (Rajkomar et al., 2019)

ประเภทของความคลาดเคลื่อนทางยา โดยเน้นข้อผิดพลาดในการสั่งจ่ายยา (Prescription Errors)

ความคลาดเคลื่อนทางยาสามารถจำแนกตามขั้นตอนของกระบวนการใช้ยา ได้แก่ การสั่งจ่ายยา การคัดลอกคำสั่งยา การเตรียมและจ่ายยา การบริหารยา และการติดตามผลการใช้ยา อย่างไรก็ตาม งานวิจัยจำนวนมากระบุว่าข้อผิดพลาดในการสั่งจ่ายยา (Prescription Errors) เป็นประเภทที่พบได้บ่อยและมีผลกระทบสูง เนื่องจากเป็นจุดเริ่มต้นของกระบวนการใช้ยา และมีอิทธิพลต่อความถูกต้องของขั้นตอนถัดไปทั้งหมด (Corny et al., 2020; Kuperman et al., 2007)

Corny และคณะ (2020) ได้ศึกษาข้อมูลใบสั่งยาจำนวนมากในโรงพยาบาล และพบว่าประมาณร้อยละ 20 ของใบสั่งยามีความคลาดเคลื่อนที่เภสัชกรสามารถตรวจพบได้ โดยประเภทของความผิดพลาดที่พบบ่อย ได้แก่ การกำหนดขนาดยาสูงหรือต่ำเกินไป การเลือกใช้รูปแบบยาที่ไม่เหมาะสม และการสั่งยาที่ไม่สอดคล้องกับลักษณะทางคลินิกของผู้ป่วย ผลการ

ศึกษานี้สะท้อนให้เห็นว่าข้อผิดพลาดในการสั่งจ่ายยายังคงเป็นปัญหาที่เกิดขึ้นจริงในกระบวนการดูแลรักษา แม้ในระบบบริการสุขภาพที่มีการควบคุมคุณภาพค่อนข้างดีแล้วก็ตาม (Corny et al., 2020)

นอกจากนี้ ความซับซ้อนของข้อมูลยาในผู้ป่วยที่มีภาวะหลายโรคร่วมและการใช้ยาหลายชนิดพร้อมกัน (polypharmacy) ยังเป็นปัจจัยสำคัญที่ทำให้ Prescription Errors เกิดขึ้นอย่างต่อเนื่อง โดยเฉพาะในกลุ่มผู้ป่วยสูงอายุหรือผู้ป่วยโรคเรื้อรังซึ่งต้องอาศัยการประเมินปฏิกริยาระหว่างยา การปรับขนาดยา และการทบทวนข้อห้ามใช้อย่างละเอียด การตรวจสอบด้วยวิธีการแบบดั้งเดิมจึงมักมีข้อจำกัดในการจัดการกับความซับซ้อนดังกล่าว (Gonzaga De Andrade Santos et al., 2020; Patel et al., 2020)

ปัจจัยเสี่ยงและบริบทที่นำไปสู่ความคลาดเคลื่อนทางยา

ปัจจัยที่เกี่ยวข้องกับการเกิดความคลาดเคลื่อนทางยามีลักษณะเป็นพหุปัจจัย (multifactorial) และสามารถแบ่งออกเป็นปัจจัยด้านผู้ป่วย บุคลากร และระบบบริการสุขภาพ โดยแต่ละปัจจัยมีความเชื่อมโยงกันและส่งผลร่วมกันต่อความเสี่ยงในการเกิดข้อผิดพลาดในกระบวนการใช้ยา (Alsulami et al., 2013; Natsiavas et al., 2019)

ในด้านผู้ป่วย กลุ่มที่มีความเสี่ยงสูงต่อความคลาดเคลื่อนทางยา ได้แก่ ผู้สูงอายุ ผู้ป่วยโรคเรื้อรัง ผู้ป่วยที่มีภาวะการทำงานของไตหรือตับบกพร่อง และผู้ป่วยที่ได้รับยาหลายชนิดร่วมกัน เนื่องจากกลุ่มดังกล่าวมักต้องการการปรับขนาดยาและการติดตามผลอย่างใกล้ชิด อีกทั้งยังมีความเสี่ยงต่อการเกิดปฏิกริยาระหว่างยาและการใช้ยาที่ไม่เหมาะสมมากกว่ากลุ่มทั่วไป (Gonzaga De Andrade Santos et al., 2020; Patel et al., 2020)

ในด้านบุคลากรทางการแพทย์ ภาระงานที่สูง ความเหนื่อยล้า ข้อจำกัดด้านเวลา และการทำงานภายใต้สภาพแวดล้อมที่ต้องตัดสินใจอย่างรวดเร็ว เป็นปัจจัยสำคัญที่เพิ่มโอกาสการเกิด human error โดยไม่เจตนา โดยเฉพาะในโรงพยาบาลที่มีจำนวนผู้ป่วยมากและความซับซ้อนของข้อมูลทางคลินิกสูง

ในด้านระบบบริการสุขภาพ แม้ระบบ Computerized Provider Order Entry (CPOE) และ Clinical Decision Support Systems (CDSS) จะช่วยลดข้อผิดพลาดบางประเภทได้ แต่ยังมีข้อจำกัดสำคัญ เช่น การแจ้งเตือนมากเกินไป (alert fatigue) การขาดการเชื่อมโยงบริบททางคลินิกอย่างลึกซึ้ง และการไม่สามารถจัดลำดับความสำคัญของความเสี่ยงได้อย่างเหมาะสม ซึ่งล้วนลดประสิทธิภาพของระบบในการป้องกันความคลาดเคลื่อนทางยา

ผลกระทบของความคลาดเคลื่อนทางยาต่อผู้ป่วย บุคลากร และระบบสุขภาพ

ผลกระทบของความคลาดเคลื่อนทางยาสามารถเกิดขึ้นได้ในหลายระดับ โดยในระดับผู้ป่วย ความคลาดเคลื่อนทางยาเป็นสาเหตุสำคัญของอาการไม่พึงประสงค์จากยา การยืดระยะเวลาการรักษาในโรงพยาบาล และการเพิ่มอัตราการกลับเข้ารับรักษาซ้ำ โดยเฉพาะในกรณีที่เกี่ยวข้องกับการใช้ยาหลายชนิดร่วมกันหรือการเกิดปฏิกริยาระหว่างยาที่มีนัยสำคัญทางคลินิก

ในระดับบุคลากรทางการแพทย์ ความคลาดเคลื่อนทางยาส่งผลต่อความเครียด ความกังวลด้านความรับผิดชอบ วิชาชีพ และภาวะหมดไฟจากการทำงาน (burnout) โดยเฉพาะในบริบทที่บุคลากรต้องรับภาระงานสูงและต้องประมวลผลข้อมูลจำนวนมากภายใต้ข้อจำกัดด้านเวลา สถานการณ์ดังกล่าวอาจส่งผลกระทบต่อคุณภาพการดูแลผู้ป่วยในระยะยาวได้ (Ranchon et al., 2023)

ในระดับระบบสาธารณสุข ความคลาดเคลื่อนทางยานำไปสู่ต้นทุนการรักษาที่เพิ่มขึ้นอย่างมีนัยสำคัญ ทั้งจากค่าใช้จ่ายในการจัดการภาวะแทรกซ้อน การใช้ทรัพยากรทางการแพทย์ที่ไม่จำเป็น และผลกระทบต่อความเชื่อมั่นของประชาชนต่อระบบบริการสุขภาพ ด้วยเหตุนี้ ความคลาดเคลื่อนทางยาจึงถูกมองว่าเป็นปัญหาความปลอดภัยที่สามารถป้องกันได้ และเป็นเป้าหมายสำคัญของการพัฒนาเทคโนโลยีและนโยบายด้านความปลอดภัยของผู้ป่วย

ระบบสนับสนุนการตัดสินใจทางคลินิก (Clinical Decision Support Systems; CDSS)

แนวคิดและบทบาทของระบบสนับสนุนการตัดสินใจทางคลินิก

ระบบสนับสนุนการตัดสินใจทางคลินิก (Clinical Decision Support Systems; CDSS) เป็นระบบสารสนเทศที่ถูกออกแบบมาเพื่อช่วยบุคลากรทางการแพทย์ในการตัดสินใจด้านการดูแลรักษาผู้ป่วย โดยอาศัยการประมวลผลข้อมูลทางคลินิก แนวทางปฏิบัติทางการแพทย์ และองค์ความรู้ที่เกี่ยวข้อง เพื่อให้คำแนะนำ แจ้งเตือน หรือแสดงข้อมูลประกอบการตัดสินใจในช่วงเวลาที่เหมาะสม ระบบดังกล่าวมีบทบาทสำคัญในการเพิ่มคุณภาพและความปลอดภัยของการดูแลผู้ป่วย โดยช่วยสนับสนุนการตัดสินใจทางคลินิกในสถานการณ์ที่มีข้อมูลจำนวนมากและมีความซับซ้อนสูง (Sutton et al., 2020)

CDSS มีบทบาทสำคัญในการลดความคลาดเคลื่อนทางการแพทย์ โดยเฉพาะในกระบวนการสั่งจ่ายยา เนื่องจากระบบสามารถช่วยตรวจสอบความถูกต้องของคำสั่งยา แจ้งเตือนข้อห้ามใช้ยา ปฏิกริยาระหว่างยา และการกำหนดขนาดยาที่ไม่เหมาะสมกับผู้ป่วย การนำ CDSS มาใช้ร่วมกับระบบ Computerized Provider Order Entry (CPOE) จึงถือเป็นองค์ประกอบสำคัญของระบบสารสนเทศทางการแพทย์ที่ช่วยเพิ่มความปลอดภัยในการใช้ยาในสถานพยาบาล (Kuperman et al., 2007)

นอกจากนี้ CDSS ยังสามารถช่วยเพิ่มความสม่ำเสมอของการตัดสินใจทางคลินิก ลดความแปรปรวนที่เกิดจากประสบการณ์และความเชี่ยวชาญของบุคลากรแต่ละราย และสนับสนุนการทำงานของบุคลากรทางการแพทย์ในสภาพแวดล้อมที่มีภาระงานสูง โดยเฉพาะเมื่อมีการประยุกต์ใช้เทคนิคการวิเคราะห์ข้อมูลหรือ machine learning เพื่อช่วยคัดแยกใบสั่งยาที่มีความเสี่ยงสูงต่อความคลาดเคลื่อนทางยา (Corny et al., 2020)

CDSS สำหรับการสั่งจ่ายยาและความปลอดภัยทางยา

ในบริบทของความปลอดภัยทางยา CDSS ถูกนำมาใช้เพื่อสนับสนุนการตรวจสอบใบสั่งยาในหลายมิติ ได้แก่ การแจ้งเตือนการแพ้ยา การตรวจจับปฏิกริยาระหว่างยา (Drug–Drug Interactions; DDIs) การตรวจสอบความเหมาะสมของขนาดยา และการแจ้งเตือนการใช้ยาที่ไม่เหมาะสมกับภาวะของผู้ป่วย (Kuperman et al., 2007)

การประยุกต์ใช้ CDSS ในระบบ Computerized Provider Order Entry (CPOE) สามารถช่วยลดอัตราการเกิดความคลาดเคลื่อนทางยาและเหตุการณ์ไม่พึงประสงค์จากยาได้อย่างมีนัยสำคัญ อย่างไรก็ตาม ประสิทธิภาพของระบบขึ้นอยู่กับคุณภาพของฐานความรู้ทางยา ความถูกต้องและความครบถ้วนของข้อมูลผู้ป่วย รวมถึงการออกแบบการแจ้งเตือนที่สอดคล้องกับบริบททางคลินิก (Kuperman et al., 2007; Sutton et al., 2020)

นอกจากนี้ การนำเทคนิคการเรียนรู้ของเครื่องมาประยุกต์ใช้กับ CDSS สามารถช่วยเพิ่มประสิทธิภาพในการคัดกรองใบสั่งยาที่มีความเสี่ยงสูงต่อความคลาดเคลื่อนทางยา โดยช่วยจัดลำดับความสำคัญของการตรวจสอบใบสั่งยาและลดภาระงานของเภสัชกรในการตรวจสอบคำสั่งยาจำนวนมากในระบบบริการสุขภาพ

ข้อจำกัดของ CDSS แบบดั้งเดิม

แม้ CDSS จะมีบทบาทสำคัญในการเพิ่มความปลอดภัยทางยา แต่ระบบ CDSS แบบดั้งเดิมยังมีข้อจำกัดหลายประการ ระบบที่อาศัยกฎที่กำหนดไว้ล่วงหน้า (rule-based systems) มักมีความยืดหยุ่นต่ำ และต้องอาศัยการปรับปรุงฐานกฎอย่างต่อเนื่องเพื่อให้ทันต่อแนวทางการรักษาและข้อมูลยาที่มีการเปลี่ยนแปลงอยู่เสมอ

อีกหนึ่งข้อจำกัดสำคัญคือปัญหา alert fatigue ซึ่งเกิดจากการแจ้งเตือนจำนวนมากที่ไม่สามารถจัดลำดับความสำคัญตามความเสี่ยงทางคลินิกได้อย่างเหมาะสม ส่งผลให้ผู้ใช้งานมีแนวโน้มเพิกเฉยต่อการแจ้งเตือน แม้ในกรณีที่มีความสำคัญต่อความปลอดภัยของผู้ป่วย (Poly et al., 2020)

นอกจากนี้ CDSS แบบดั้งเดิมยังมีข้อจำกัดในการประมวลผลข้อมูลทางคลินิกที่มีความซับซ้อน โดยเฉพาะข้อมูลที่อยู่ในรูปแบบข้อความอิสระจากเวชระเบียนอิเล็กทรอนิกส์ ซึ่งทำให้ระบบไม่สามารถตีความบริบททางคลินิกของผู้ป่วยได้อย่างครอบคลุม (Natsiavas et al., 2019)

บทบาทของ CDSS ในการพัฒนาไปสู่ระบบ AI

จากข้อจำกัดของ CDSS แบบดั้งเดิม งานวิจัยในช่วงหลังจึงมุ่งเน้นการพัฒนาระบบ CDSS ที่ผสมผสานเทคโนโลยีปัญญาประดิษฐ์ (Artificial Intelligence; AI) เพื่อเพิ่มความสามารถในการวิเคราะห์ข้อมูลทางคลินิกจำนวนมากและปรับปรุงความแม่นยำของการแจ้งเตือน โดยเทคนิค machine learning สามารถช่วยให้ระบบเรียนรู้จากข้อมูลจริงและให้คำแนะนำที่สอดคล้องกับบริบทของผู้ป่วยมากขึ้น

เทคโนโลยี AI ยังช่วยให้ระบบสามารถวิเคราะห์ข้อมูลทั้งที่มีโครงสร้างและไม่มีโครงสร้างจากเวชระเบียนอิเล็กทรอนิกส์ ซึ่งช่วยเพิ่มศักยภาพของระบบสนับสนุนการตัดสินใจทางคลินิกในสถานการณ์ที่มีข้อมูลจำนวนมากและมีความซับซ้อนสูง (Topol, 2019)

อย่างไรก็ตาม การประยุกต์ใช้ AI ในระบบสนับสนุนการตัดสินใจทางคลินิกยังคงมีความท้าทาย โดยเฉพาะในด้านความโปร่งใสของโมเดลและความสามารถในการอธิบายผลลัพธ์ ซึ่งเป็นปัจจัยสำคัญต่อความน่าเชื่อถือและการนำระบบไปใช้จริงในบริบททางการแพทย์

ด้วยเหตุนี้ CDSS จึงถือเป็นรากฐานสำคัญของการพัฒนาระบบอัจฉริยะด้านความปลอดภัยทางยา และเป็นพื้นฐานของการประยุกต์ใช้เทคโนโลยีปัญญาประดิษฐ์ขั้นสูง เช่น machine learning และ knowledge-based AI เพื่อสนับสนุนการตัดสินใจทางคลินิกในงานวิจัยนี้

เทคโนโลยีปัญญาประดิษฐ์ในระบบสาธารณสุข

แนวคิดพื้นฐานของปัญญาประดิษฐ์ในทางการแพทย์

ปัญญาประดิษฐ์ (Artificial Intelligence; AI) หมายถึงระบบคอมพิวเตอร์ที่สามารถเลียนแบบความสามารถของมนุษย์ในการเรียนรู้ การให้เหตุผล และการตัดสินใจ โดยอาศัยอัลกอริธึมทางคณิตศาสตร์และสถิติในการประมวลผลข้อมูล ในบริบทของระบบสาธารณสุข AI ถูกนำมาใช้เพื่อจัดการกับข้อมูลทางการแพทย์ที่มีปริมาณมาก มีความหลากหลาย และมีความซับซ้อนสูง ซึ่งเกินขีดความสามารถของการวิเคราะห์ข้อมูลโดยมนุษย์เพียงอย่างเดียว (Topol, 2019)

การพัฒนาเทคโนโลยี AI ได้มีบทบาทสำคัญต่อการเปลี่ยนแปลงระบบการแพทย์สมัยใหม่ โดยสามารถนำไปใช้ในการวิเคราะห์ข้อมูลสุขภาพ การสนับสนุนการตัดสินใจทางคลินิก การวินิจฉัยโรค และการเพิ่มประสิทธิภาพของกระบวนการดูแลผู้ป่วย โดยเฉพาะในบริบทที่ต้องอาศัยการประมวลผลข้อมูลจำนวนมากและการวิเคราะห์ข้อมูลเชิงซับซ้อนในระยะเวลาอันสั้น (Rajkomar et al., 2019; Topol, 2019)

Machine Learning และ Deep Learning ในงานด้านสาธารณสุข

Machine Learning (ML) เป็นแขนงหนึ่งของปัญญาประดิษฐ์ที่มุ่งเน้นให้ระบบสามารถเรียนรู้รูปแบบหรือความสัมพันธ์ของข้อมูลจากตัวอย่างข้อมูลจำนวนมากโดยไม่จำเป็นต้องกำหนดกฎตายตัวล่วงหน้า เทคโนโลยี ML ถูกนำมาใช้ในงานด้านสาธารณสุขอย่างแพร่หลาย เช่น การพยากรณ์ผลลัพธ์ทางคลินิก การจำแนกกลุ่มผู้ป่วย การวิเคราะห์ข้อมูลเวชระเบียน อิเล็กทรอนิกส์ และการตรวจจับความผิดปกติจากข้อมูลสุขภาพ

การประยุกต์ใช้ ML ในระบบสาธารณสุขช่วยให้สามารถวิเคราะห์ข้อมูลที่มีตัวแปรจำนวนมากและความสัมพันธ์เชิงซับซ้อนได้ดีกว่าระบบที่ใช้กฎตายตัว (rule-based systems) อย่างไรก็ตาม ประสิทธิภาพของโมเดล ML ขึ้นอยู่กับคุณภาพและความครอบคลุมของข้อมูลฝึกสอน (training data) เป็นอย่างมาก หากข้อมูลมีความลำเอียงหรือไม่ครอบคลุมบริบททางคลินิกที่หลากหลาย อาจส่งผลให้โมเดลมีความแม่นยำลดลงหรือเกิดปัญหาการทำนายที่ไม่เหมาะสมในสถานการณ์จริง (Rajkomar et al., 2019)

Deep Learning (DL) เป็นรูปแบบหนึ่งของ ML ที่ใช้โครงข่ายประสาทเทียมหลายชั้น (deep neural networks) เพื่อเรียนรู้ความสัมพันธ์เชิงลึกของข้อมูล DL ถูกนำมาใช้กันอย่างแพร่หลายในงานวิเคราะห์ภาพทางการแพทย์ การวิเคราะห์สัญญาณชีวภาพ และการประมวลผลข้อมูลสุขภาพขนาดใหญ่ อย่างไรก็ตาม โมเดล DL มักมีความซับซ้อนสูงและยากต่อการอธิบายผลลัพธ์ ซึ่งเป็นข้อจำกัดสำคัญในการนำไปใช้ในบริบททางคลินิกที่ต้องการความโปร่งใสในการตัดสินใจ (Topol, 2019)

การประมวลผลภาษาธรรมชาติ (Natural Language Processing; NLP) กับข้อมูลทางการแพทย์

ข้อมูลทางการแพทย์จำนวนมากอยู่ในรูปแบบข้อความอิสระ (unstructured text) เช่น บันทึกเวชระเบียน รายงานทางคลินิก และใบสั่งยา ซึ่งทำให้การนำข้อมูลเหล่านี้มาใช้ในการวิเคราะห์เชิงระบบมีความท้าทาย เทคโนโลยีการประมวลผลภาษาธรรมชาติ (Natural Language Processing; NLP) จึงถูกพัฒนาขึ้นเพื่อช่วยให้ระบบ AI สามารถเข้าใจ วิเคราะห์ และดึงข้อมูลที่มีความหมายจากข้อความดังกล่าวได้ (Bhatt et al., 2021)

การประยุกต์ใช้ NLP ในระบบสาธารณสุขช่วยให้สามารถนำข้อมูลจากเวชระเบียนอิเล็กทรอนิกส์และเอกสารทางการแพทย์มาใช้ในการสนับสนุนการตัดสินใจทางคลินิกได้อย่างมีประสิทธิภาพ อย่างไรก็ตาม ระบบ NLP แบบดั้งเดิมยังมีข้อจำกัดในการเข้าใจบริบทเชิงลึกของภาษาและความหมายทางคลินิกที่ซับซ้อน ซึ่งมักต้องอาศัยการพัฒนาโมเดลเฉพาะงานหรือการใช้ฐานความรู้ทางการแพทย์เพิ่มเติมเพื่อเพิ่มความแม่นยำของผลลัพธ์ (Natsiavas et al., 2019)

ข้อจำกัดและความท้าทายของ AI ในระบบสาธารณสุข

แม้เทคโนโลยี AI จะมีศักยภาพสูงในการยกระดับระบบสาธารณสุข แต่การนำไปใช้ในบริบททางคลินิกยังคงเผชิญกับความท้าทายหลายประการ หนึ่งในประเด็นสำคัญคือปัญหาความลำเอียงของข้อมูล (data bias) ซึ่งอาจส่งผลให้โมเดล AI ให้ผลลัพธ์ที่ไม่สอดคล้องกับกลุ่มประชากรบางกลุ่ม หากข้อมูลที่ใช้ในการฝึกสอนไม่ครอบคลุมความหลากหลายของประชากรผู้ป่วย

อีกหนึ่งข้อจำกัดสำคัญคือความสามารถในการอธิบายผลลัพธ์ของโมเดล (explainability) โดยเฉพาะในโมเดล ML และ DL ที่มีโครงสร้างซับซ้อน ซึ่งอาจลดความเชื่อมั่นของบุคลากรทางการแพทย์ในการนำ AI มาใช้ประกอบการตัดสินใจทางคลินิก (Topol, 2019)

นอกจากนี้ การนำ AI มาใช้ในงานทางคลินิกยังมีความท้าทายด้านความปลอดภัย ความน่าเชื่อถือของผลลัพธ์ และประเด็นด้านจริยธรรม โดยเฉพาะในกรณีที่ระบบ AI ถูกนำมาใช้ในการตัดสินใจทางคลินิกโดยอัตโนมัติแทนบุคลากรทางการแพทย์ ซึ่งทำให้เกิดข้อถกเถียงด้านกฎระเบียบและการกำกับดูแลเทคโนโลยี AI ในระบบสาธารณสุข (Mesko & Topol, 2023a)

การพัฒนา AI จากระบบวิเคราะห์ข้อมูลสู่ Generative AI

จากข้อจำกัดของ AI แบบวิเคราะห์ข้อมูล (discriminative models) งานวิจัยในช่วงหลังจึงให้ความสนใจกับ Generative AI ซึ่งเป็นเทคโนโลยีที่สามารถสร้างข้อมูลใหม่และให้เหตุผลเชิงบริบทจากข้อมูลที่มีอยู่ โดยเฉพาะ Large Language Models (LLMs) ที่มีความสามารถในการประมวลผลภาษาเชิงลึกและเชื่อมโยงข้อมูลจากหลายแหล่งเข้าด้วยกัน (Mesko & Topol, 2023a)

อย่างไรก็ตาม การใช้ Generative AI ในบริบททางคลินิกยังมีข้อจำกัดด้านความถูกต้องและความน่าเชื่อถือของข้อมูล รวมถึงความเสี่ยงจากการสร้างข้อมูลที่ไม่สอดคล้องกับหลักฐานทางการแพทย์ ซึ่งทำให้การนำเทคโนโลยีดังกล่าวไปใช้ในงานด้านสาธารณสุขจำเป็นต้องมีการกำกับดูแลและการผสมผสานเข้ากับฐานความรู้ทางการแพทย์ที่เชื่อถือได้ (Chelli et al., 2024; The Lancet Digital Health, 2023)

ด้วยเหตุนี้ แนวทางหนึ่งที่ได้รับ الاهتمامคือการผสมผสาน Generative AI เข้ากับฐานความรู้ทางการแพทย์ เพื่อพัฒนาเป็น Knowledge-Based Generative AI ที่สามารถให้ผลลัพธ์ที่สอดคล้องกับหลักฐานเชิงวิชาการและบริบททางคลินิกได้อย่างเหมาะสม แนวคิดดังกล่าวจึงเป็นพื้นฐานสำคัญของงานวิจัยนี้ ซึ่งมุ่งเน้นการนำ Knowledge-Based Generative AI มาประยุกต์ใช้ในการจำแนกประเภทใบสั่งยาและจัดการความคลาดเคลื่อนทางยาอย่างเป็นระบบ

การใช้ปัญญาประดิษฐ์เพื่อตรวจสอบและจำแนกใบสั่งยา

การประยุกต์ใช้ Machine Learning ในการตรวจจับความคลาดเคลื่อนทางยา

การนำ Machine Learning (ML) มาประยุกต์ใช้ในการตรวจสอบใบสั่งยาได้รับความนิยมอย่างมากในช่วงหลายปีที่ผ่านมา เนื่องจาก ML สามารถเรียนรู้รูปแบบของความผิดพลาดจากข้อมูลใบสั่งยาจำนวนมาก และช่วยคัดแยกใบสั่งยาที่มีความเสี่ยงสูงต่อความคลาดเคลื่อนทางยาได้อย่างมีประสิทธิภาพ โดยงานวิจัยในระยะแรกมักใช้แนวทาง supervised learning

ซึ่งอาศัยข้อมูลใบสั่งยาที่ได้รับการตรวจสอบแล้วจากเภสัชกรเป็นชุดข้อมูลอ้างอิง (ground truth) เพื่อฝึกสอนโมเดลในการจำแนกประเภทของใบสั่งยา (Corny et al., 2020)

การศึกษาที่ใช้ข้อมูลใบสั่งยาจำนวนมากจากระบบเวชระเบียนอิเล็กทรอนิกส์แสดงให้เห็นว่าโมเดล ML สามารถระบุใบสั่งยาที่มีความเสี่ยงต่อความคลาดเคลื่อนทางยาได้อย่างแม่นยำ และมีประสิทธิภาพสูงกว่าระบบสนับสนุนการตัดสินใจแบบดั้งเดิมที่อาศัยกฎตายตัว (rule-based systems) โดยเฉพาะเมื่อพิจารณาจากตัวชี้วัดด้านการจำแนกประเภท เช่น F1-score และพื้นที่ใต้กราฟ ROC (AUROC) ซึ่งสะท้อนถึงความสามารถของโมเดลในการตรวจจับความผิดพลาดได้อย่างแม่นยำ (Corny et al., 2020)

อย่างไรก็ตาม การใช้ ML ในการตรวจสอบใบสั่งยายังมีข้อจำกัดหลายประการ โดยเฉพาะความสามารถในการอธิบายเหตุผลของการจำแนกผลลัพธ์ของโมเดล และการพึ่งพาข้อมูลฝึกสอนที่มีคุณภาพสูง ซึ่งอาจไม่สามารถครอบคลุมบริบททางคลินิกที่หลากหลายได้ทั้งหมด (Rajkomar et al., 2019)

การประเมินประสิทธิภาพของโมเดล AI ในการจำแนกใบสั่งยา

การประเมินประสิทธิภาพของโมเดล AI ในงานตรวจสอบใบสั่งยามักใช้ตัวชี้วัดด้านการจำแนกประเภท (classification metrics) เช่น Precision, Recall, F1-score, AUROC และ AUCPR เพื่อประเมินทั้งความสามารถในการตรวจจับข้อผิดพลาดและความสามารถในการลดการแจ้งเตือนที่ไม่จำเป็น

การศึกษาที่ใช้เทคนิค ML เพื่อกรองการแจ้งเตือนจากระบบ CDSS พบว่าโมเดลสามารถลดจำนวนการแจ้งเตือนที่ไม่จำเป็นได้อย่างมีนัยสำคัญ ในขณะที่ยังคงรักษาความสามารถในการตรวจจับข้อผิดพลาดที่มีความสำคัญทางคลินิกไว้ได้ ซึ่งสะท้อนให้เห็นถึงศักยภาพของ AI ในการช่วยลดภาระของระบบแจ้งเตือนและเพิ่มประสิทธิภาพของระบบสนับสนุนการตัดสินใจทางคลินิก (Liu et al., 2022)

อย่างไรก็ตาม การประเมินประสิทธิภาพของโมเดล AI ในบริบททางคลินิกยังจำเป็นต้องพิจารณาปัจจัยอื่นร่วมด้วย เช่น ความน่าเชื่อถือของผลลัพธ์ ความสอดคล้องกับการตัดสินใจของผู้เชี่ยวชาญ และผลกระทบต่อกระบวนการทำงานจริงของบุคลากรทางการแพทย์

การใช้ AI ร่วมกับ CDSS เพื่อลด Alert Fatigue และเพิ่มความแม่นยำ

งานวิจัยในช่วงหลังมุ่งเน้นการผสมผสานเทคโนโลยี AI เข้ากับระบบ CDSS แทนการใช้ AI หรือ CDSS แบบแยกส่วน แนวทางดังกล่าวช่วยให้ระบบสามารถเรียนรู้จากข้อมูลการใช้งานจริงและปรับปรุงการแจ้งเตือนให้สอดคล้องกับบริบทของผู้ป่วยมากขึ้น

การประยุกต์ใช้ ML เพื่อจัดลำดับความสำคัญของการแจ้งเตือนจาก CDSS สามารถช่วยลดปัญหา alert fatigue ซึ่งเป็นหนึ่งในอุปสรรคสำคัญของระบบแจ้งเตือนแบบดั้งเดิม โดยการวิเคราะห์ข้อมูลเกี่ยวกับโรค ยา และบริบทของผู้ป่วย เพื่อให้ระบบสามารถคัดกรองการแจ้งเตือนที่มีความสำคัญสูงต่อความปลอดภัยของผู้ป่วยได้อย่างมีประสิทธิภาพ (Poly et al., 2020)

แนวทางการผสมผสาน AI เข้ากับ CDSS ช่วยให้ระบบสามารถปรับการแจ้งเตือนให้เหมาะสมกับบริบทของผู้ป่วยจริง ลดการแจ้งเตือนทั่วไปที่ไม่มีความสำคัญ และเพิ่มความแม่นยำของการแจ้งเตือนที่เกี่ยวข้องกับความเสี่ยงต่อผู้ป่วย อย่างไรก็ตามระบบลักษณะนี้ยังคงเผชิญกับข้อจำกัดด้านความสามารถในการตีความผลลัพธ์และการอธิบายเหตุผลของโมเดล AI

ข้อจำกัดของการใช้ AI แบบ Data-Driven ในการตรวจสอบใบสั่งยา

แม้ AI แบบ data-driven จะมีประสิทธิภาพสูงในการตรวจจับรูปแบบความผิดปกติจากข้อมูลขนาดใหญ่ แต่ข้อจำกัดสำคัญคือการขาดความสามารถในการให้เหตุผลเชิงตรรกะทางคลินิก และการพึ่งพาข้อมูลฝึกสอนที่อาจไม่ครอบคลุมทุกสถานการณ์ทางคลินิก

โมเดล AI ที่เรียนรู้จากข้อมูลเพียงอย่างเดียวอาจให้ผลลัพธ์ที่ดูสมเหตุสมผลเชิงสถิติ แต่ไม่สอดคล้องกับหลักฐานทางคลินิกในบางกรณี นอกจากนี้ โมเดลดังกล่าวยังมีความเสี่ยงต่อปัญหาความลำเอียงของข้อมูล (data bias) และอาจไม่สามารถจัดการกับสถานการณ์ใหม่ที่ไม่เคยปรากฏในชุดข้อมูลฝึกสอนได้อย่างเหมาะสม (Rajkomar et al., 2019)

ข้อจำกัดเหล่านี้เป็นหนึ่งในเหตุผลสำคัญที่ทำให้การพัฒนา AI ในระบบสาธารณสุขจำเป็นต้องคำนึงถึงการผสมผสานองค์ความรู้ทางคลินิกเข้ากับการเรียนรู้จากข้อมูล

ความจำเป็นของแนวทาง Knowledge-Based AI ในการจำแนกใบสั่งยา

จากข้อจำกัดของ AI แบบ data-driven งานวิจัยในช่วงหลังจึงเริ่มให้ความสำคัญกับการผสมผสานความรู้ทางการแพทย์เข้ากับระบบ AI เพื่อเพิ่มความถูกต้อง ความน่าเชื่อถือ และความสามารถในการอธิบายผลลัพธ์ของโมเดล

แนวคิด Knowledge-Based AI ช่วยให้ระบบสามารถอ้างอิงข้อมูลเชิงหลักฐาน เช่น แนวทางการรักษา ข้อบ่งใช้ยา และปฏิกริยาระหว่างยา ในการวิเคราะห์ใบสั่งยา ซึ่งช่วยเพิ่มความแม่นยำและความโปร่งใสของการตัดสินใจของระบบ (Natsiavas et al., 2019)

การใช้ knowledge graph และฐานความรู้เชิงสาเหตุยังช่วยให้ระบบสามารถวิเคราะห์ความสัมพันธ์ระหว่างยา โรค และบริบทของผู้ป่วยได้อย่างมีประสิทธิภาพมากขึ้น ซึ่งมีบทบาทสำคัญในการตรวจจับปฏิกริยาระหว่างยาและสนับสนุนการตัดสินใจทางคลินิก (Luo et al., 2024; Lyu et al., 2023)

แนวทางดังกล่าวเป็นพื้นฐานสำคัญของการพัฒนา Knowledge-Based Generative AI ซึ่งผสมผสานความสามารถในการให้เหตุผลเชิงบริบทของ Generative AI เข้ากับฐานความรู้ทางคลินิก เพื่อใช้ในการจำแนกประเภทใบสั่งยาและจัดการความคลาดเคลื่อนทางยาอย่างเป็นระบบในงานวิจัยนี้

เทคโนโลยีปัญญาประดิษฐ์และฐานความรู้ในระบบสาธารณสุข

เทคโนโลยีปัญญาประดิษฐ์ (Artificial Intelligence; AI) ได้เข้ามามีบทบาทสำคัญอย่างยิ่งในระบบสาธารณสุขสมัยใหม่ โดยเฉพาะในด้านการสนับสนุนการตัดสินใจทางคลินิก การวิเคราะห์ข้อมูลสุขภาพขนาดใหญ่ และการเพิ่มประสิทธิภาพในการให้บริการทางการแพทย์ AI หมายถึงระบบคอมพิวเตอร์ที่สามารถเลียนแบบความสามารถของมนุษย์ใน

การเรียนรู้ การให้เหตุผล และการแก้ปัญหา โดยอาศัยเทคนิคต่าง ๆ เช่น Machine Learning, Deep Learning และ Natural Language Processing (NLP) (Rajkomar et al., 2019; Topol, 2019)

ในบริบทของระบบสาธารณสุข AI ถูกนำมาใช้ในหลายด้าน อาทิ การวินิจฉัยโรค การพยากรณ์ผลลัพธ์ทางคลินิก การวิเคราะห์ภาพทางการแพทย์ และการจัดการข้อมูลเวชระเบียนอิเล็กทรอนิกส์ (Electronic Health Records; EHR) ซึ่งช่วยให้บุคลากรทางการแพทย์สามารถเข้าถึงข้อมูลที่ถูกต้องและทันสมัย ส่งผลให้การดูแลผู้ป่วยมีประสิทธิภาพและปลอดภัยมากยิ่งขึ้น

ฐานความรู้ (Knowledge Base) เป็นองค์ประกอบสำคัญที่ช่วยเสริมศักยภาพของ AI ในระบบสาธารณสุข โดยฐานความรู้หมายถึงแหล่งรวบรวมข้อมูลเชิงโครงสร้างและกึ่งโครงสร้าง เช่น แนวทางการรักษา ข้อมูลยา ความสัมพันธ์ระหว่างยาและโรค รวมถึงหลักฐานเชิงประจักษ์จากงานวิจัยทางการแพทย์ ฐานความรู้ดังกล่าวทำให้ระบบ AI สามารถอ้างอิงข้อมูลทางวิชาการที่เชื่อถือได้ และให้ผลลัพธ์ที่สอดคล้องกับบริบททางคลินิกมากขึ้น (Sutton et al., 2020)

การผสมผสานเทคโนโลยี AI เข้ากับฐานความรู้ทางการแพทย์นำไปสู่การพัฒนาาระบบที่เรียกว่า Knowledge-Based AI ซึ่งมีความสามารถในการให้เหตุผลเชิงตรรกะ ควบคู่กับการเรียนรู้จากข้อมูลจริง ระบบลักษณะนี้ช่วยลดข้อจำกัดของ AI แบบดั้งเดิมที่อาศัยเพียงรูปแบบข้อมูล (pattern-based learning) และเพิ่มความสามารถในการอธิบายผลลัพธ์ (Explainability) ซึ่งเป็นประเด็นสำคัญในการนำ AI ไปใช้ในงานทางการแพทย์ (Balestra et al., 2021)

ในช่วงไม่กี่ปีที่ผ่านมา Generative AI ได้รับความสนใจอย่างมากในระบบสาธารณสุข เนื่องจากสามารถสร้างเนื้อหาใหม่ เช่น ข้อความทางการแพทย์ รายงานทางคลินิก หรือการสรุปข้อมูลผู้ป่วย โดยอาศัยการเรียนรู้จากข้อมูลขนาดใหญ่ เมื่อผสาน Generative AI เข้ากับฐานความรู้ทางการแพทย์ จะช่วยเพิ่มความแม่นยำและความน่าเชื่อถือของผลลัพธ์ ลดความเสี่ยงจากข้อมูลที่ไม่ถูกต้อง และสนับสนุนการตัดสินใจของบุคลากรทางการแพทย์ได้อย่างมีประสิทธิภาพ (Singh et al., 2023; Soroush et al., 2024)

ดังนั้น เทคโนโลยีปัญญาประดิษฐ์ร่วมกับฐานความรู้จึงถือเป็นกลไกสำคัญในการพัฒนาระบบสาธารณสุขสู่ระบบอัจฉริยะ (Intelligent Healthcare Systems) ที่สามารถเพิ่มคุณภาพการรักษา ลดภาระงานของบุคลากร และยกระดับความปลอดภัยของผู้ป่วยในระยะยาว ซึ่งเป็นพื้นฐานสำคัญสำหรับการนำ AI ไปประยุกต์ใช้ในด้านความปลอดภัยทางยาและการป้องกันความคลาดเคลื่อนทางยาในงานวิจัยนี้

ระบบฐานความรู้ (Knowledge-Based Systems) ในการแพทย์และเภสัชกรรม

แนวคิดและโครงสร้างของระบบฐานความรู้ (Knowledge-Based Systems)

ระบบฐานความรู้ (Knowledge-Based Systems; KBS) เป็นรูปแบบหนึ่งของระบบปัญญาประดิษฐ์ที่ออกแบบมาเพื่อสนับสนุนการตัดสินใจโดยอาศัยองค์ความรู้ที่ถูกจัดเก็บอย่างเป็นระบบ แทนการเรียนรู้จากข้อมูลเชิงสถิติเพียงอย่างเดียว โดยระบบลักษณะนี้มักประกอบด้วยองค์ประกอบหลัก ได้แก่ ฐานความรู้ (knowledge base) กลไกการให้เหตุผล (inference engine) และส่วนติดต่อผู้ใช้ (user interface) ซึ่งทำงานร่วมกันเพื่อวิเคราะห์ปัญหาและให้คำแนะนำที่สอดคล้องกับหลักเกณฑ์หรือแนวทางปฏิบัติที่กำหนดไว้ (Natsiavas et al., 2019)

ในบริบทของการแพทย์และเภสัชกรรม ระบบฐานความรู้ถูกพัฒนาขึ้นเพื่อช่วยจัดการกับความซับซ้อนของข้อมูลทางคลินิก โดยการรวบรวมข้อเท็จจริง กฎเกณฑ์ และแนวทางเวชปฏิบัติที่ได้รับการยอมรับทางวิชาการไว้ในรูปแบบที่ระบบสามารถนำไปใช้ในการให้เหตุผลเชิงตรรกะได้ ระบบลักษณะนี้มีจุดเด่นด้านความโปร่งใส (transparency) และความสามารถในการอธิบายเหตุผลของผลลัพธ์ ซึ่งเป็นคุณสมบัติสำคัญสำหรับการนำไปใช้ในบริบททางคลินิกที่ต้องการความน่าเชื่อถือและความสามารถในการตรวจสอบได้

ฐานความรู้ทางคลินิกและเภสัชกรรม

ฐานความรู้ทางคลินิกและเภสัชกรรมเป็นองค์ประกอบสำคัญของระบบฐานความรู้ โดยประกอบด้วยข้อมูลเกี่ยวกับข้อบ่งใช้ยา ข้อห้ามใช้ยา ปฏิกริยาระหว่างยา การปรับขนาดยาตามภาวะของผู้ป่วย รวมถึงแนวทางการรักษาที่อ้างอิงจากหลักฐานเชิงประจักษ์ ฐานความรู้เหล่านี้มักถูกพัฒนาโดยอาศัยแหล่งข้อมูลที่เชื่อถือได้ เช่น แนวทางเวชปฏิบัติ งานวิจัยทางคลินิก และฐานข้อมูลยาที่ได้รับการยอมรับในวงการแพทย์

การประยุกต์ใช้แนวทาง knowledge engineering ในการจัดการความปลอดภัยด้านยาพบว่าระบบที่อาศัยฐานความรู้สามารถช่วยลดความคลาดเคลื่อนทางยาได้อย่างมีประสิทธิภาพ โดยเฉพาะในกรณีที่เกี่ยวข้องผิดพลาดมีลักษณะเป็นตรรกะทางคลินิกที่ชัดเจน เช่น การใช้ยาที่มีข้อห้ามใช้ผู้ป่วยบางกลุ่ม หรือการกำหนดขนาดยาที่ไม่เหมาะสมกับสถานะของผู้ป่วย (Natsiavas et al., 2019)

อย่างไรก็ตาม ฐานความรู้ทางคลินิกยังมีความท้าทายด้านการบำรุงรักษาและการอัปเดตข้อมูล เนื่องจากองค์ความรู้ทางการแพทย์มีการเปลี่ยนแปลงอย่างต่อเนื่อง หากฐานความรู้ไม่ได้รับการปรับปรุงอย่างสม่ำเสมอ อาจนำไปสู่การให้คำแนะนำที่ไม่สอดคล้องกับแนวทางการรักษาปัจจุบัน

Knowledge Graph และการเชื่อมโยงข้อมูลทางการแพทย์

ในช่วงหลัง แนวคิดของ knowledge graph ได้รับความสนใจอย่างมากในการพัฒนาระบบฐานความรู้ทางการแพทย์ เนื่องจากสามารถแทนความสัมพันธ์เชิงซับซ้อนระหว่างข้อมูลทางการแพทย์ได้ดีกว่าการใช้รูปแบบดั้งเดิม Knowledge graph เป็นโครงสร้างข้อมูลที่ใช้แทนความสัมพันธ์ระหว่างเอนทิตีต่าง ๆ เช่น ยา โรค อาการ และผลข้างเคียง ในรูปแบบของโหนด (nodes) และความสัมพันธ์ (edges)

การประยุกต์ใช้ knowledge graph ร่วมกับข้อมูลเชิงความหมายสามารถช่วยเพิ่มความสามารถในการให้เหตุผลเชิงคลินิก และช่วยเติมเต็มข้อมูลที่ขาดหายไปในฐานความรู้ได้อย่างมีประสิทธิภาพ (Lan et al., 2021)

นอกจากนี้ การผสมผสาน knowledge graph เข้ากับเทคนิคการเรียนรู้ของเครื่องยังสามารถเพิ่มความแม่นยำในการวิเคราะห์ความสัมพันธ์ของข้อมูลยา เช่น การทำนายปฏิกริยาระหว่างยา (drug-drug interactions) ซึ่งเป็นองค์ประกอบสำคัญของความปลอดภัยทางยา (Luo et al., 2024)

บทบาทของ Knowledge-Based Systems ในการสนับสนุนการตัดสินใจทางคลินิก

ระบบฐานความรู้มีบทบาทสำคัญในการสนับสนุนการตัดสินใจทางคลินิก โดยเฉพาะในสถานการณ์ที่ต้องอาศัยการให้เหตุผลตามหลักเกณฑ์และแนวทางเวชปฏิบัติที่ชัดเจน ระบบลักษณะนี้สามารถช่วยแพทย์และเภสัชกรตรวจสอบความเหมาะสมของการสั่งจ่ายยา ลดภาระการจดจำข้อมูลจำนวนมาก และเพิ่มความสม่ำเสมอของการตัดสินใจทางคลินิก

การใช้อนุความรู้เชิงสาเหตุ (causal knowledge) ในระบบสนับสนุนการตัดสินใจทางคลินิกยังสามารถช่วยเพิ่มความแม่นยำและความน่าเชื่อถือของผลลัพธ์ เมื่อเทียบกับระบบที่อาศัยการเรียนรู้จากข้อมูลเพียงอย่างเดียว (Lyu et al., 2023)

นอกจากนี้ ระบบฐานความรู้ยังมีข้อได้เปรียบด้านความสามารถในการอธิบายผลลัพธ์ของระบบ ซึ่งช่วยให้บุคลากรทางการแพทย์สามารถตรวจสอบเหตุผลของคำแนะนำที่ระบบให้ได้ และเพิ่มความเชื่อมั่นในการนำระบบไปใช้ในการตัดสินใจทางคลินิก

อย่างไรก็ตาม ระบบฐานความรู้แบบดั้งเดิมยังมีข้อจำกัดด้านความยืดหยุ่น และความสามารถในการจัดการข้อมูลที่ไม่เป็นโครงสร้าง เช่น ข้อความจากเวชระเบียนหรือใบสั่งยา ซึ่งเป็นข้อมูลที่พบได้บ่อยในระบบสารสนเทศสมัยใหม่

จาก Knowledge-Based Systems สู่ Knowledge-Based Generative AI

จากข้อจำกัดของระบบฐานความรู้แบบดั้งเดิม งานวิจัยในช่วงหลังจึงมุ่งเน้นการผสมผสานความรู้เข้ากับเทคโนโลยีปัญญาประดิษฐ์ขั้นสูง โดยเฉพาะ Generative AI เพื่อเพิ่มความสามารถในการประมวลผลข้อมูลเชิงบริบทและข้อมูลที่ไม่มีโครงสร้าง

แนวคิด Knowledge-Based Generative AI ช่วยให้ระบบสามารถให้เหตุผลเชิงคลินิกบนพื้นฐานขององค์ความรู้ที่เชื่อถือได้ ขณะเดียวกันยังคงความยืดหยุ่นในการตีความข้อมูลใหม่และการประมวลผลภาษาธรรมชาติ ซึ่งเป็นคุณสมบัติสำคัญในการวิเคราะห์ข้อมูลจากเวชระเบียนและใบสั่งยา

แนวทางดังกล่าวได้รับการมองว่าเป็นทิศทางสำคัญของการพัฒนา AI ทางทางการแพทย์ เนื่องจากสามารถลดความเสี่ยงจากผลลัพธ์ที่ไม่สอดคล้องกับหลักฐานทางคลินิก และเพิ่มความน่าเชื่อถือของระบบในการนำไปใช้จริงในระบบบริการสุขภาพ (Mesko & Topol, 2023a)

แนวคิดนี้จึงเป็นกรอบสำคัญของงานวิจัยนี้ ซึ่งมุ่งเน้นการประยุกต์ใช้ Knowledge-Based Generative AI ในการจำแนกประเภทใบสั่งยาและจัดการความคลาดเคลื่อนทางยาอย่างเป็นระบบ

แนวคิดและหลักการของ Generative AI ในงานด้านสารสนเทศสุขภาพ

แนวคิดพื้นฐานของ Generative AI และ Large Language Models

Generative AI เป็นกลุ่มของเทคโนโลยีปัญญาประดิษฐ์ที่มีความสามารถในการสร้างข้อมูลใหม่ เช่น ข้อความ รูปภาพ หรือโครงสร้างข้อมูล โดยอาศัยการเรียนรู้จากข้อมูลขนาดใหญ่ที่มีอยู่เดิม แตกต่างจาก AI แบบดั้งเดิมที่มุ่งเน้นการจำแนกหรือทำนายผลลัพธ์จากข้อมูลเป็นหลัก Generative AI มุ่งเน้นการสร้างผลลัพธ์ที่สอดคล้องกับบริบทและรูปแบบของ

ข้อมูลต้นแบบ ซึ่งทำให้เทคโนโลยีนี้มีศักยภาพสูงในการประมวลผลข้อมูลที่มีความซับซ้อนและหลากหลายในระบบสาธารณสุข (Mesko & Topol, 2023a; Topol, 2019)

Large Language Models (LLMs) เป็นรูปแบบหนึ่งของ Generative AI ที่ใช้โมเดลภาษาขนาดใหญ่ในการเรียนรู้ความสัมพันธ์ของคำ ความหมาย และบริบทในข้อความ ทำให้สามารถประมวลผลข้อมูลข้อความอิสระได้อย่างมีประสิทธิภาพ ซึ่งมีความสำคัญอย่างยิ่งในงานด้านการแพทย์ เนื่องจากข้อมูลจำนวนมากในระบบสุขภาพอยู่ในรูปของข้อความจากเวชระเบียน รายงานทางคลินิก และใบสั่งยา (Topol, 2019)

การประยุกต์ใช้ Generative AI ในระบบสาธารณสุข

Generative AI ได้รับการนำมาประยุกต์ใช้ในหลายด้านของระบบสาธารณสุข เช่น การสรุปเวชระเบียน การสร้างรายงานทางคลินิก การช่วยค้นคว้าและสังเคราะห์วรรณกรรมทางการแพทย์ ตลอดจนการสนับสนุนการตัดสินใจของบุคลากรทางการแพทย์ เทคโนโลยีนี้มีศักยภาพในการลดภาระงานด้านเอกสารและเพิ่มประสิทธิภาพของกระบวนการดูแลผู้ป่วยในสภาพแวดล้อมที่มีข้อมูลจำนวนมากและเปลี่ยนแปลงอย่างรวดเร็ว (Kuperman et al., 2007; Mesko & Topol, 2023a; Topol, 2019)

ในบริบทของเภสัชกรรม Generative AI มีศักยภาพในการช่วยวิเคราะห์ข้อมูลยา สรุปข้อมูลทางคลินิกจากหลายแหล่ง และสนับสนุนการตัดสินใจเกี่ยวกับการใช้ยา โดยเฉพาะในสถานการณ์ที่ข้อมูลอยู่ในรูปแบบข้อความอิสระและต้องอาศัยการตีความเชิงบริบท อย่างไรก็ตาม การใช้เทคโนโลยีดังกล่าวในงานที่เกี่ยวข้องกับความปลอดภัยของผู้ป่วยยังจำเป็นต้องพิจารณาความถูกต้องของผลลัพธ์และความน่าเชื่อถือของข้อมูลอย่างรอบคอบ (Bhatt et al., 2021; The Lancet Digital Health, 2023)

ข้อจำกัดของ Generative AI ในบริบททางคลินิก

แม้ Generative AI จะมีศักยภาพสูง แต่การนำไปใช้ในบริบททางคลินิกยังคงมีข้อจำกัดสำคัญหลายประการ หนึ่งในประเด็นสำคัญคือปัญหาความถูกต้องของข้อมูลและภาวะหลอน (hallucination) ซึ่งหมายถึงการที่โมเดลสร้างข้อมูลที่ดูสมเหตุสมผล แต่ไม่ถูกต้องตามข้อเท็จจริงหรือไม่มีหลักฐานรองรับ ความเสี่ยงดังกล่าวเป็นประเด็นสำคัญอย่างยิ่งในระบบสาธารณสุข เนื่องจากข้อมูลที่คลาดเคลื่อนอาจส่งผลโดยตรงต่อการตัดสินใจทางคลินิกและความปลอดภัยของผู้ป่วย (Chelli et al., 2024; The Lancet Digital Health, 2023)

ข้อจำกัดอีกประการหนึ่งคือความสามารถในการอธิบายผลลัพธ์ (explainability) โดย Generative AI มักให้ผลลัพธ์ในลักษณะข้อความที่มีความสับสนในหลายภาษา แต่ไม่สามารถแสดงเหตุผลเชิงตรรกะหรือหลักฐานที่รองรับอย่างชัดเจน ซึ่งอาจลดความเชื่อมั่นของบุคลากรทางการแพทย์ต่อการนำผลลัพธ์ไปใช้ประกอบการตัดสินใจ (Crossnohere et al., 2022; Mesko & Topol, 2023a)

นอกจากนี้ การประยุกต์ใช้ Generative AI ในระบบสาธารณสุขยังมีความท้าทายด้านจริยธรรม กฎหมาย และความรับผิดชอบ โดยเฉพาะในกรณีที่ระบบถูกนำไปใช้ในลักษณะที่อาจมีผลต่อการตัดสินใจรักษาผู้ป่วยโดยตรง จึงจำเป็นต้องมีกรอบการกำกับดูแลที่เหมาะสม และต้องออกแบบการใช้งานให้อยู่ในขอบเขตของการสนับสนุนการตัดสินใจ มากกว่าการตัดสินใจแทนบุคลากรทางการแพทย์ (Crossnohere et al., 2022; Mesko & Topol, 2023a)

แนวทางการเพิ่มความน่าเชื่อถือของ Generative AI ด้วยฐานความรู้

จากข้อจำกัดดังกล่าว งานวิจัยในช่วงหลังจึงให้ความสนใจต่อการผสมผสาน Generative AI เข้ากับฐานความรู้ทางการแพทย์ เพื่อเพิ่มความถูกต้อง ความน่าเชื่อถือ และความสามารถในการอธิบายผลลัพธ์ของระบบ แนวทางนี้ช่วยให้โมเดลสามารถอ้างอิงข้อมูลจากแหล่งที่ผ่านการตรวจสอบแล้ว เช่น แนวทางเวชปฏิบัติ ฐานข้อมูลยา และองค์ความรู้เชิงโครงสร้างทางคลินิก ซึ่งช่วยลดความเสี่ยงจากการสร้างข้อมูลที่ไม่สอดคล้องกับหลักฐานทางวิชาการ (Natsiavas et al., 2019; Sutton et al., 2020)

การผสมผสานองค์ความรู้เชิงโครงสร้างเข้ากับระบบ AI ยังช่วยเพิ่มความสามารถในการให้เหตุผลเชิงคลินิก และทำให้ระบบมีความเหมาะสมมากขึ้นสำหรับการใช้งานในบริบทที่เกี่ยวข้องกับความปลอดภัยของผู้ป่วย โดยเฉพาะเมื่อระบบต้องวิเคราะห์ข้อมูลหลายมิติที่เกี่ยวข้องกับยา โรค ข้อห้ามใช้ และปัจจัยเฉพาะของผู้ป่วย (Coulet et al., 2018; Lan et al., 2021; Luo et al., 2024; Lyu et al., 2023)

บทบาทของ Generative AI ต่อการพัฒนา Knowledge-Based Generative AI

จากการทบทวนวรรณกรรม Generative AI สามารถมองได้ว่าเป็นเทคโนโลยีที่มีศักยภาพสูงในการจัดการข้อมูลทางการแพทย์ที่ไม่เป็นโครงสร้างและความซับซ้อน อย่างไรก็ตาม การนำไปใช้ในงานที่เกี่ยวข้องกับความปลอดภัยของผู้ป่วยจำเป็นต้องมีการควบคุมที่ชัดเจนและต้องมีแหล่งอ้างอิงทางคลินิกที่น่าเชื่อถือเพื่อกำกับผลลัพธ์ของระบบ

การผสมผสาน Generative AI เข้ากับระบบฐานความรู้จึงเป็นแนวทางที่เหมาะสมในการลดข้อจำกัดด้านความถูกต้อง ความน่าเชื่อถือ และความสามารถในการอธิบายผลลัพธ์ แนวคิดดังกล่าวจึงเป็นพื้นฐานสำคัญของงานวิจัยนี้ ซึ่งมุ่งเน้นการพัฒนาและประเมินประสิทธิภาพของ Knowledge-Based Generative AI สำหรับการจำแนกประเภทใบสั่งยาและการจัดการความคลาดเคลื่อนทางยาในบริบทของระบบสาธารณสุขจริง

การใช้ Knowledge-Based Generative AI ในการตรวจสอบใบสั่งยา

แนวคิดของ Knowledge-Based Generative AI ในบริบททางคลินิก

Knowledge-Based Generative AI เป็นแนวทางการพัฒนาปัญญาประดิษฐ์ที่ผสมผสานความสามารถของ Generative AI ในการประมวลผลภาษาและให้เหตุผลเชิงบริบท เข้ากับฐานความรู้ทางการแพทย์และเภสัชกรรมที่ผ่านการตรวจสอบแล้ว แนวคิดนี้เกิดขึ้นเพื่อลดข้อจำกัดของ Generative AI แบบดั้งเดิมที่อาศัยการเรียนรู้จากข้อมูลเพียงอย่างเดียว ซึ่งอาจให้ผลลัพธ์ที่ไม่สอดคล้องกับหลักฐานทางคลินิกหรือไม่สามารถอธิบายเหตุผลของผลลัพธ์ได้อย่างเพียงพอ (Amin et al., 2023; Crossnohere et al., 2022; Natsiavas et al., 2019)

ในบริบทของการตรวจสอบใบสั่งยา ระบบลักษณะนี้สามารถตีความข้อมูลใบสั่งยาที่อยู่ในรูปแบบข้อความอิสระ และเชื่อมโยงข้อมูลดังกล่าวเข้ากับองค์ความรู้ทางคลินิก เช่น ข้อบ่งใช้ยา ข้อห้ามใช้ ปฏิกริยาระหว่างยา และหลักการปรับขนาดยา ตามลักษณะผู้ป่วย เพื่อสนับสนุนการตัดสินใจของบุคลากรทางการแพทย์อย่างเป็นระบบ (Iancu et al., 2023)

การผสมผสานฐานความรู้กับ Generative AI เพื่อเพิ่มความถูกต้องและความน่าเชื่อถือ

การผสานฐานความรู้เข้ากับ Generative AI ช่วยเพิ่มความถูกต้องของผลลัพธ์ และเพิ่มความสอดคล้องกับบริบททางคลินิก เนื่องจากระบบสามารถอ้างอิงข้อมูลผ่านการตรวจสอบแล้ว แทนการสร้างคำตอบจากรูปแบบทางสถิติของข้อมูลเพียงอย่างเดียว แนวทางนี้ช่วยลดความคลาดเคลื่อนของผลลัพธ์ และเพิ่มความเหมาะสมของการนำ AI ไปใช้ในงานทางการแพทย์ที่มีความเสี่ยงสูง (Kuperman et al., 2007; Natsiavas et al., 2019)

ในด้านความปลอดภัยทางยา การใช้ฐานความรู้ช่วยให้ระบบสามารถให้เหตุผลเชิงตรรกะเกี่ยวกับความสัมพันธ์ระหว่างยา โรค อาการ และข้อจำกัดเฉพาะของผู้ป่วย ซึ่งเป็นบริบทที่ระบบ AI แบบ data-driven มักมีข้อจำกัด โดยเฉพาะเมื่อเผชิญกับข้อมูลที่ซับซ้อนหรือไม่เคยปรากฏในชุดข้อมูลฝึกสอนมาก่อน (Mahomedradja et al., 2023; Rajkomar et al., 2019)

การประยุกต์ใช้ Knowledge-Based AI ในการตรวจสอบความปลอดภัยของยา

งานวิจัยในช่วงหลังสะท้อนให้เห็นว่าแนวทางที่ผสานฐานความรู้เข้ากับ AI สามารถช่วยตรวจสอบความปลอดภัยของการสั่งจ่ายยาได้อย่างมีประสิทธิภาพ โดยเฉพาะในประเด็นที่ต้องอาศัยการให้เหตุผลเชิงคลินิก เช่น การตรวจจับปฏิกิริยาระหว่างยา การใช้ยาที่มีข้อห้ามใช้ในผู้ป่วยบางกลุ่ม และการปรับขนาดยาตามการทำงานของอวัยวะ (Natsiavas et al., 2019)

การใช้ knowledge graph ร่วมกับโมเดลเชิงลึกยังสามารถเพิ่มความแม่นยำในการทำนายปฏิกิริยาระหว่างยา ขณะที่ฐานความรู้เชิงสาเหตุสามารถช่วยให้ระบบสนับสนุนการตัดสินใจทางคลินิกมีความสอดคล้องกับการให้เหตุผลของผู้เชี่ยวชาญมากขึ้น ผลการศึกษาเหล่านี้สะท้อนให้เห็นถึงศักยภาพของ Knowledge-Based AI ในการจัดการปัญหาที่มีความซับซ้อนสูงในงานด้านความปลอดภัยทางยา (Luo et al., 2024; Lyu et al., 2023)

ข้อได้เปรียบของ Knowledge-Based Generative AI เหนือแนวทางเดิม

เมื่อเปรียบเทียบกับระบบ CDSS แบบ rule-based และ AI แบบ data-driven แล้ว Knowledge-Based Generative AI มีข้อได้เปรียบหลายประการ

ประการแรก ระบบสามารถประมวลผลข้อมูลที่ไม่เป็นโครงสร้าง เช่น ข้อความในใบสั่งยาและบันทึกทางคลินิก พร้อมเชื่อมโยงข้อมูลเหล่านั้นเข้ากับองค์ความรู้ทางคลินิกที่มีโครงสร้างได้อย่างมีประสิทธิภาพ (Lan et al., 2021)

ประการที่สอง ระบบมีศักยภาพในการอธิบายเหตุผลของผลลัพธ์ในเชิงตรรกะทางคลินิก ซึ่งช่วยเพิ่มความเชื่อมั่นของผู้ใช้งาน และสนับสนุนการทำงานในลักษณะ decision support มากกว่าการตัดสินใจแทนบุคลากรทางการแพทย์ (Crossnohere et al., 2022; Sutton et al., 2020)

ประการที่สาม แนวทางนี้ช่วยลดความเสี่ยงจากความลำเอียงของข้อมูลและปัญหา hallucination ที่มักพบใน Generative AI แบบทั่วไป เนื่องจากผลลัพธ์ถูกกำกับด้วยฐานความรู้ที่ผ่านการตรวจสอบแล้ว และสามารถตรวจสอบย้อนกลับไปยังหลักฐานหรือกฎเกณฑ์ที่เกี่ยวข้องได้มากขึ้น (Mesko & Topol, 2023b)

ข้อจำกัดและช่องว่างของงานวิจัยที่เกี่ยวข้อง

แม้ Knowledge-Based Generative AI จะมีศักยภาพสูง แต่จากการทบทวนวรรณกรรมพบว่างานวิจัยส่วนใหญ่ยังอยู่ในระดับแนวคิด การพัฒนาเชิงระบบ หรือการทดลองในสภาพแวดล้อมจำลอง ขณะที่การประเมินประสิทธิภาพในบริบทการใช้งานจริง โดยเฉพาะในงานด้านเภสัชกรรมโรงพยาบาล ยังมีจำนวนจำกัด (Crossnohere et al., 2022; Mesko & Topol, 2023b)

นอกจากนี้ งานวิจัยจำนวนมากมุ่งเน้นการตรวจจับความผิดพลาดเฉพาะด้าน เช่น การทำนายปฏิกิริยาระหว่างยา หรือการเสริมประสิทธิภาพของระบบสนับสนุนการตัดสินใจทางคลินิก แต่ยังขาดแนวทางที่สามารถจำแนกประเภทใบสั่งยาตามลักษณะของความคลาดเคลื่อนอย่างเป็นระบบ ซึ่งเป็นประเด็นสำคัญต่อการจัดการความเสี่ยงและการปรับปรุงคุณภาพการสั่งจ่ายยาในระดับระบบบริการสุขภาพ

ช่องว่างดังกล่าวนำไปสู่ความจำเป็นในการพัฒนา Knowledge-Based Generative AI ที่สามารถทำงานร่วมกับเภสัชกรในสถานพยาบาลจริง เพื่อจำแนกประเภทใบสั่งยาและสนับสนุนการจัดการความคลาดเคลื่อนทางยาอย่างมีประสิทธิภาพ ซึ่งเป็นวัตถุประสงค์หลักของงานวิจัยนี้

ปัญหาภาวะหลอน (Hallucination) และความน่าเชื่อถือของ Generative AI

ความหมายและลักษณะของภาวะหลอนของปัญญาประดิษฐ์ (AI Hallucination)

ภาวะหลอนของปัญญาประดิษฐ์ (AI Hallucination) หมายถึงปรากฏการณ์ที่ระบบ Generative AI สร้างข้อมูลหรือคำตอบที่ดูมีเหตุผลและสอดคล้องกับบริบททางภาษา แต่ไม่ถูกต้องตามข้อเท็จจริงหรือไม่มีหลักฐานทางวิชาการรองรับ ปัญหาดังกล่าวพบได้บ่อยใน Large Language Models เนื่องจากโมเดลถูกออกแบบให้คาดการณ์ลำดับคำตามความน่าจะเป็นทางสถิติ มากกว่าการตรวจสอบความถูกต้องของข้อมูลในเชิงตรรกะหรือการอ้างอิงหลักฐานโดยตรง (The Lancet Digital Health, 2023)

ภาวะหลอนจึงถือเป็นหนึ่งในความเสี่ยงสำคัญที่สุดของการนำ Generative AI ไปใช้ในงานด้านการแพทย์และสาธารณสุข เนื่องจากข้อมูลที่ผิดพลาดอาจนำไปสู่การตัดสินใจทางคลินิกที่ไม่เหมาะสม และส่งผลกระทบต่อความปลอดภัยของผู้ป่วยโดยตรง (Mesko & Topol, 2023b; The Lancet Digital Health, 2023)

รูปแบบของภาวะหลอนและผลกระทบต่อการใช้งานเชิงวิชาการและคลินิก

ภาวะหลอนของ Generative AI สามารถเกิดขึ้นได้ในหลายรูปแบบ เช่น การสร้างข้อเท็จจริงที่ไม่ถูกต้อง การอ้างอิงงานวิจัยหรือเอกสารที่ไม่มีอยู่จริง และการตีความข้อมูลทางคลินิกผิดพลาด ซึ่งล้วนเป็นความเสี่ยงสำคัญในบริบทของการใช้ AI เพื่อสนับสนุนงานวิชาการและการตัดสินใจทางการแพทย์ (Chelli et al., 2024)

ผลการประเมินความแม่นยำของ LLMs ในการสร้างเอกสารอ้างอิงสำหรับงาน systematic review แสดงให้เห็นว่าโมเดลสามารถสร้างข้อมูลอ้างอิงที่ผิดพลาดหรือไม่มีอยู่จริงได้ในอัตราสูง แม้โมเดลรุ่นใหม่จะมีประสิทธิภาพดีขึ้น แต่ปัญหา

ความน่าเชื่อถือยังคงเป็นอุปสรรคสำคัญต่อการนำ Generative AI ไปใช้เป็นเครื่องมือหลักในงานวิชาการและงานคลินิก (Coulet et al., 2018)

ในบริบทของการสั่งจ่ายยา ความผิดพลาดที่เกิดจาก hallucination อาจนำไปสู่การให้ข้อมูลที่ไม่สอดคล้องกับข้อบ่งใช้ยา การประเมินความเสี่ยงของปฏิกิริยาระหว่างยาที่ไม่ถูกต้อง หรือการละเลยข้อห้ามใช้ยาที่สำคัญ ซึ่งล้วนมีความเสี่ยงสูงต่อความปลอดภัยของผู้ป่วย

ความลำเอียงของข้อมูล (Bias) และผลต่อความน่าเชื่อถือของ AI

นอกจากปัญหา hallucination แล้ว Generative AI ยังมีความเสี่ยงด้านความลำเอียงของข้อมูล เนื่องจากข้อมูลที่ใช้ในการฝึกโมเดลมักมาจากแหล่งข้อมูลบางประเภทหรือบางบริบทเป็นหลัก ทำให้ผลลัพธ์ของโมเดลอาจสะท้อนอคติของข้อมูลต้นทาง และอาจไม่สอดคล้องกับบริบทของระบบสุขภาพในประเทศหรือสถานพยาบาลที่แตกต่างกัน (Crossnohere et al., 2022; Klumpp et al., 2021)

ในบริบททางเภสัชกรรม ความลำเอียงของข้อมูลอาจส่งผลต่อการแนะนำการใช้ยาในกลุ่มผู้ป่วยเฉพาะ เช่น ผู้สูงอายุ ผู้ป่วยโรคเรื้อรัง หรือผู้ป่วยที่มีโรคร่วมหลายโรค ซึ่งเป็นกลุ่มที่มีความเสี่ยงสูงต่อความคลาดเคลื่อนทางยาและต้องการการพิจารณาทางคลินิกอย่างรอบคอบ

แนวทางการลดความเสี่ยงจาก Hallucination ในงานด้านการแพทย์

จากความท้าทายดังกล่าว แนวทางหนึ่งที่ได้รับความสนใจคือการจำกัดขอบเขตการทำงานของ Generative AI ให้อยู่ภายใต้กรอบของฐานความรู้ทางคลินิกที่ผ่านการตรวจสอบแล้ว ซึ่งช่วยเพิ่มความถูกต้องของผลลัพธ์และเพิ่มความสามารถในการอธิบายเหตุผลของคำตอบของระบบ

การผสานฐานความรู้เชิงโครงสร้าง เช่น knowledge graph หรือกฎเกณฑ์ทางคลินิก เข้ากับระบบ AI ช่วยลดความเสี่ยงของการสร้างข้อมูลที่ไม่ถูกต้อง และทำให้ระบบทำงานในลักษณะของ decision support ภายใต้การกำกับของผู้เชี่ยวชาญ มากกว่าการตัดสินใจแทนบุคลากรทางการแพทย์ (Kuperman et al., 2007; Lyu et al., 2023)

ความสำคัญของความน่าเชื่อถือและการกำกับดูแลในการใช้ Generative AI

การนำ Generative AI มาใช้ในระบบสาธารณสุขจำเป็นต้องคำนึงถึงความน่าเชื่อถือ ความโปร่งใส และการกำกับดูแลอย่างเหมาะสม เพื่อให้มั่นใจว่าระบบจะไม่ก่อให้เกิดอันตรายต่อผู้ป่วย และไม่ละเมิดสิทธิของผู้เชี่ยวชาญทางการแพทย์ในการตัดสินใจทางคลินิก (Crossnohere et al., 2022; Mesko & Topol, 2023b)

ในบริบทของงานวิจัยนี้ การเลือกใช้ Knowledge-Based Generative AI เพื่อจำแนกประเภทใบสั่งยา จึงเป็นแนวทางที่ช่วยลดความเสี่ยงจาก hallucination และเพิ่มความน่าเชื่อถือของผลลัพธ์ เพื่อให้สามารถนำไปใช้สนับสนุนการทำงานของเภสัชกรในสถานพยาบาลจริงได้อย่างปลอดภัย

ประเภทของโมเดลการจำแนกข้อมูล: Binary, Multiclass และ Multilabel Classification

การจำแนกข้อมูล (classification) เป็นหนึ่งในเทคนิคพื้นฐานของการเรียนรู้ของเครื่อง (Machine Learning) ที่ใช้ในการจัดหมวดหมู่ข้อมูลตามคุณลักษณะที่กำหนดไว้ โดยโมเดลจะเรียนรู้รูปแบบจากข้อมูลตัวอย่างและใช้ความรู้ดังกล่าวในการทำนายหมวดหมู่ของข้อมูลใหม่ เทคนิคการจำแนกถูกนำมาใช้กันอย่างแพร่หลายในงานด้านสาธารณสุข เช่น การวินิจฉัยโรค การทำนายความเสี่ยงของผู้ป่วย และการตรวจจับความผิดปกติของข้อมูลทางคลินิก (Gatto et al., 2025; Tsoumakas & Katakis, n.d.)

ในบริบทของการวิเคราะห์ใบสั่งยา การจำแนกข้อมูลสามารถใช้เพื่อระบุใบสั่งยานั้นมีความคลาดเคลื่อนหรือไม่ และหากมีความคลาดเคลื่อน สามารถจำแนกประเภทของข้อผิดพลาดได้อย่างเป็นระบบ โดยทั่วไปโมเดลการจำแนกสามารถแบ่งออกเป็นสามประเภทหลัก ได้แก่ Binary Classification, Multiclass Classification และ Multilabel Classification ซึ่งแต่ละรูปแบบมีลักษณะการใช้งานที่แตกต่างกันตามโครงสร้างของปัญหา (Zhang & Zhou, 2014)

Binary Classification

Binary Classification เป็นรูปแบบการจำแนกที่ง่ายที่สุด โดยโมเดลจะจัดข้อมูลออกเป็นสองกลุ่ม เช่น “มีความคลาดเคลื่อน” และ “ไม่มีความคลาดเคลื่อน” โมเดลลักษณะนี้มักถูกใช้ในขั้นตอนการคัดกรองเบื้องต้นเพื่อระบุข้อมูลที่มีความเสี่ยงสูงและต้องการการตรวจสอบเพิ่มเติม (Bishop, 2006)

ในบริบทของการตรวจสอบใบสั่งยา Binary Classification สามารถใช้เพื่อคัดกรองใบสั่งยาที่มีความเสี่ยงต่อความคลาดเคลื่อนทางยา เพื่อช่วยให้เภสัชกรสามารถมุ่งเน้นการตรวจสอบใบสั่งยาที่มีความเสี่ยงสูงได้อย่างมีประสิทธิภาพมากขึ้น

Multiclass Classification

Multiclass Classification เป็นการจำแนกข้อมูลออกเป็นหลายกลุ่ม โดยแต่ละตัวอย่างข้อมูลจะถูกจัดให้อยู่ในเพียงหนึ่งหมวดหมู่เท่านั้น ตัวอย่างเช่น ระบบอาจจำแนกความคลาดเคลื่อนทางยาออกเป็นหลายประเภท เช่น ความผิดพลาดด้านขนาดยา ความผิดพลาดด้านความถี่ในการใช้ยา หรือความผิดพลาดด้านรูปแบบยา (Heaton, 2018)

การจำแนกประเภทในลักษณะนี้ช่วยให้สามารถระบุประเภทของปัญหาได้อย่างชัดเจน ซึ่งมีประโยชน์ต่อการวิเคราะห์สาเหตุของความคลาดเคลื่อน และสามารถนำข้อมูลไปใช้ในการปรับปรุงกระบวนการสั่งจ่ายยาและการจัดการความปลอดภัยทางยาในระดับระบบได้

Multilabel Classification

Multilabel Classification เป็นรูปแบบการจำแนกที่ข้อมูลหนึ่งตัวอย่างสามารถมีได้มากกว่าหนึ่งป้ายกำกับ (label) พร้อมกัน กล่าวคือ ข้อมูลหนึ่งรายการอาจถูกจัดอยู่ในหลายหมวดหมู่ในเวลาเดียวกัน (Zhang & Zhou, 2014)

ในบริบทของใบสั่งยา ความคลาดเคลื่อนทางยาอาจเกิดขึ้นได้หลายลักษณะในใบสั่งยาเดียวกัน เช่น อาจมีทั้งปัญหาด้านขนาดยาและปัญหาด้านความถี่ในการใช้ยา ดังนั้น โมเดล Multilabel Classification จึงมีความเหมาะสมสำหรับ

สถานการณ์ที่ต้องการสะท้อนความซับซ้อนของข้อมูลทางคลินิก ซึ่งมักมีหลายปัจจัยที่เกิดขึ้นร่วมกัน (Tsoumakas & Katakis, n.d.)

ความสำคัญของรูปแบบการจำแนกต่อการวิเคราะห์ใบสั่งยา

การเลือกใช้รูปแบบการจำแนกที่เหมาะสมมีความสำคัญต่อการออกแบบระบบวิเคราะห์ข้อมูลและการพัฒนาโมเดลปัญญาประดิษฐ์ เนื่องจากโครงสร้างของปัญหาการจำแนกจะส่งผลต่อการเลือกอัลกอริธึม วิธีการประเมินผล และความสามารถของระบบในการสะท้อนลักษณะของปัญหาที่เกิดขึ้นจริง (Goodfellow et al., 2016)

สำหรับงานวิจัยนี้ การจำแนกประเภทใบสั่งยาถูกออกแบบเพื่อสะท้อนลักษณะของความคลาดเคลื่อนทางยาที่อาจเกิดขึ้นในกระบวนการสั่งจ่ายยา โดยใช้แนวคิดของโมเดลการจำแนกข้อมูลเป็นพื้นฐานในการพัฒนาระบบ Knowledge-Based Generative AI เพื่อสนับสนุนการตรวจสอบใบสั่งยาและเพิ่มความปลอดภัยทางยาในระบบบริการสุขภาพ

สรุปวรรณกรรมและช่องว่างของงานวิจัย (Research Gap)

จากการทบทวนวรรณกรรมที่เกี่ยวข้องพบว่า ความคลาดเคลื่อนทางยา โดยเฉพาะข้อผิดพลาดในการสั่งจ่ายยา ยังคงเป็นปัญหาสำคัญด้านความปลอดภัยของผู้ป่วยในระบบสาธารณสุข ทั้งในระดับกระบวนการดูแลรักษา ระดับบุคลากรทางการแพทย์ และระดับระบบบริการสุขภาพโดยรวม ความคลาดเคลื่อนดังกล่าวอาจเกิดขึ้นได้จากหลายปัจจัยร่วมกัน ไม่ว่าจะเป็นความซับซ้อนของข้อมูลผู้ป่วยและข้อมูลยา ภาระงานของบุคลากร ข้อจำกัดด้านเวลา การใช้ยาหลายชนิดร่วมกัน ตลอดจนข้อจำกัดของระบบสนับสนุนการตัดสินใจที่มีอยู่ในปัจจุบัน ปัญหาเหล่านี้ส่งผลให้การป้องกันและจัดการความคลาดเคลื่อนทางยายังคงเป็นประเด็นที่ต้องได้รับการพัฒนาอย่างต่อเนื่อง

การทบทวนวรรณกรรมยังชี้ให้เห็นว่า ระบบ CDSS มีบทบาทสำคัญในการเพิ่มความปลอดภัยทางยา โดยเฉพาะในด้านการตรวจสอบความเหมาะสมของใบสั่งยา การแจ้งเตือนปฏิกิริยาระหว่างยา และการลดความผิดพลาดในการสั่งจ่ายยา อย่างไรก็ตาม ระบบ CDSS แบบ Rule based ยังคงมีข้อจำกัดหลายประการ เช่น ความยืดหยุ่นต่ำ ความสามารถในการปรับตัวต่อบริบททางคลินิกที่ซับซ้อนมีจำกัด และปัญหาการแจ้งเตือนมากเกินไปจนเกิดความจำเจ ซึ่งอาจลดประสิทธิภาพของระบบในการใช้งานจริง

การพัฒนาเทคโนโลยีปัญญาประดิษฐ์ในระบบสาธารณสุข โดยเฉพาะ Machine Learning และ Deep Learning ได้เข้ามาเพิ่มศักยภาพในการวิเคราะห์ข้อมูลทางคลินิกจำนวนมาก และช่วยคัดแยกใบสั่งยาที่มีความเสี่ยงสูงต่อความคลาดเคลื่อนทางยาได้อย่างมีประสิทธิภาพมากขึ้นเมื่อเปรียบเทียบกับระบบแบบอาศัยกฎเพียงอย่างเดียว นอกจากนี้ เทคโนโลยี LLM ยังช่วยให้สามารถนำข้อมูลจากข้อความอิสระ เช่น เวชระเบียน รายงานทางคลินิก และใบสั่งยา มาใช้ประโยชน์ในการวิเคราะห์และสนับสนุนการตัดสินใจได้ดีขึ้น อย่างไรก็ตาม แนวทางที่อาศัยการเรียนรู้จากข้อมูลเพียงอย่างเดียวยังคงมีข้อจำกัดสำคัญ ได้แก่ ความสามารถในการแปลผล ความเสี่ยงจากความลำเอียงของข้อมูล และการพึ่งพาข้อมูลฝึกสอนที่อาจไม่ครอบคลุมความหลากหลายของสถานการณ์ทางคลินิกจริง

ในอีกด้านหนึ่ง ระบบ knowledge-based มีจุดเด่นด้านความโปร่งใส ความสามารถในการให้เหตุผลเชิงตรรกะ และความสอดคล้องกับหลักฐานทางวิชาการ โดยเฉพาะในการสนับสนุนการตัดสินใจที่เกี่ยวข้องกับข้อบ่งชี้ยา ข้อห้ามใช้ การปรับขนาดยา และปฏิกิริยาระหว่างยา การพัฒนา knowledge graph และโครงสร้างความรู้เชิงสาเหตุยิ่งช่วยให้ระบบ

สามารถเชื่อมโยงข้อมูลทางคลินิกที่ซับซ้อนและเพิ่มความแม่นยำในการวิเคราะห์ได้มากขึ้น อย่างไรก็ตาม ระบบฐานความรู้แบบดั้งเดิมยังมีข้อจำกัดในด้านความยืดหยุ่น การจัดการข้อมูลที่ไม่เป็นโครงสร้าง และการรองรับข้อมูลทางคลินิกที่หลากหลายและเปลี่ยนแปลงอย่างรวดเร็ว

อย่างไรก็ตาม Generative AI และ Large Language Models ถือว่าเป็นเทคโนโลยีที่มีศักยภาพสูงในการจัดการข้อมูลข้อความทางการแพทย์ การสรุปข้อมูล และการสนับสนุนการตัดสินใจในงานทางคลินิก อย่างไรก็ตาม การนำ Generative AI ไปใช้ในระบบสาธารณสุขยังคงเผชิญกับข้อกังวลสำคัญด้านความถูกต้องของข้อมูล ความสามารถในการอธิบายเหตุผลของผลลัพธ์ ความลำเอียงของข้อมูล และโดยเฉพาะปัญหาภาวะหลอน ซึ่งอาจทำให้ระบบสร้างข้อมูลที่ดูน่าเชื่อถือแต่ไม่ถูกต้องหรือไม่สอดคล้องกับหลักฐานทางคลินิก ความท้าทายเหล่านี้ทำให้การใช้ Generative AI ในงานที่เกี่ยวข้องกับความปลอดภัยของผู้ป่วยจำเป็นต้องอยู่ภายใต้กรอบที่มีการควบคุมและตรวจสอบอย่างเหมาะสม

จึงเห็นได้ชัดว่าแนวทางที่มีศักยภาพสูงในปัจจุบันคือการผสมผสานความสามารถของ Generative AI เข้ากับระบบฐานความรู้ทางการแพทย์และเภสัชกรรม เพื่อพัฒนาเป็น Knowledge-Based Generative AI ซึ่งสามารถรวมข้อดีของทั้งสองแนวคิดเข้าด้วยกัน กล่าวคือ มีทั้งความสามารถในการประมวลผลข้อมูลที่ไม่เป็นโครงสร้าง การตีความข้อมูลเชิงบริบท และการให้เหตุผลบนพื้นฐานขององค์ความรู้ที่เชื่อถือได้ แนวทางดังกล่าวช่วยเพิ่มความถูกต้องของผลลัพธ์ ลดข้อจำกัดของระบบ AI แบบอาศัยข้อมูลเพียงอย่างเดียว และเพิ่มความเหมาะสมต่อการนำไปใช้ในงานสนับสนุนการตัดสินใจทางคลินิก

อย่างไรก็ตาม เมื่อพิจารณาจากวรรณกรรมที่ผ่านมา พบว่างานวิจัยส่วนใหญ่ยังมุ่งเน้นการประยุกต์ใช้ AI หรือระบบฐานความรู้เพื่อแก้ปัญหาเฉพาะด้าน เช่น การตรวจจับปฏิกิริยาระหว่างยา การกรองการแจ้งเตือนจากระบบ CDSS การปรับขนาดยา หรือการสนับสนุนการตัดสินใจทางคลินิกในประเด็นเฉพาะโรค ขณะที่งานวิจัยที่มุ่งเน้นการนำ Knowledge-Based Generative AI มาใช้ในการ “จำแนกประเภทใบสั่งยา” ตามลักษณะของความคลาดเคลื่อนทางยาอย่างเป็นระบบยังมีจำนวนจำกัด โดยเฉพาะการศึกษาในบริบทการใช้งานจริงภายในโรงพยาบาลและการประเมินผลร่วมกับเภสัชกรวิชาชีพ

ดังนั้น ช่องว่างสำคัญของงานวิจัยในปัจจุบัน คือ การขาดระบบที่สามารถผสมผสานการประมวลผลข้อมูลข้อความจากใบสั่งยาเข้ากับองค์ความรู้ทางคลินิกอย่างเป็นระบบ เพื่อใช้ในการจำแนกประเภทใบสั่งยาและสนับสนุนการตรวจจับความคลาดเคลื่อนทางยาในสถานการณ์จริงได้อย่างมีประสิทธิภาพ นอกจากนี้ ยังขาดการประเมินระบบดังกล่าวในมิติที่ครอบคลุมทั้งด้านความแม่นยำ ความน่าเชื่อถือ ความสามารถในการอธิบายผลลัพธ์ และความสอดคล้องกับการตัดสินใจของเภสัชกร

ด้วยเหตุนี้ งานวิจัยนี้จึงมุ่งพัฒนาและประเมินประสิทธิภาพของระบบ Knowledge-Based Generative AI สำหรับการจำแนกประเภทใบสั่งยาและการจัดการความคลาดเคลื่อนทางยาในบริบทของโรงพยาบาลจริง โดยมุ่งหวังให้ระบบสามารถทำหน้าที่เป็นเครื่องมือสนับสนุนการตัดสินใจของเภสัชกรได้อย่างมีประสิทธิภาพ ปลอดภัย และสอดคล้องกับบริบททางคลินิก อันจะนำไปสู่การยกระดับความปลอดภัยทางยาและการพัฒนาระบบบริการสุขภาพที่มีคุณภาพมากยิ่งขึ้น

บทที่ 3

วิธีดำเนินการวิจัย

การศึกษานี้เป็นการวิจัยเชิงทดลอง (Experimental Research) มีวัตถุประสงค์เพื่อพัฒนาและประเมินประสิทธิภาพของระบบ Knowledge-Based Generative AI ในการจำแนกประเภทใบสั่งยา (Prescription Classification) โดยใช้แนวคิดการจำแนกแบบหลายป้ายกำกับ (Multi-label Classification) เพื่อระบุประเภทของความคลาดเคลื่อนทางยาที่อาจเกิดขึ้นในใบสั่งยาแต่ละรายการ

การศึกษานี้เน้นการเปรียบเทียบผลลัพธ์การจำแนกของระบบปัญญาประดิษฐ์กับการประเมินของเภสัชกรวิชาชีพ เพื่อประเมินความแม่นยำ ความน่าเชื่อถือ และความสอดคล้องของระบบในการสนับสนุนการตรวจสอบใบสั่งยาในบริบทของสถานพยาบาลจริง

ประชากรและกลุ่มตัวอย่าง

ประชากรในการวิจัย

ประชากรเป้าหมายของการวิจัย คือ ใบสั่งยาทั้งหมดที่ได้รับการส่งจ่ายภายในโรงพยาบาลกรุงเทพมหานครขอนแก่น ในช่วงระยะเวลา 12 เดือนของการศึกษา ตั้งแต่วันที่ 1 มีนาคม พ.ศ. 2568 ถึง 28 กุมภาพันธ์ พ.ศ. 2569 โดยเป็นการเก็บข้อมูลย้อนหลัง (Retrospective Data Collection) จากระบบเวชระเบียนอิเล็กทรอนิกส์ของโรงพยาบาล

กลุ่มตัวอย่าง

กลุ่มตัวอย่างในการศึกษาคือใบสั่งยาที่ถูกดึงมาจากระบบเวชระเบียนอิเล็กทรอนิกส์ (Electronic Health Records; EHRs) ของโรงพยาบาลในช่วงเวลาที่กำหนด โดยมีเกณฑ์คัดเลือกดังต่อไปนี้

เกณฑ์การคัดเข้า

1. เป็นใบสั่งยาที่มีการส่งจ่ายในช่วงวันที่ 1 มีนาคม พ.ศ. 2568 ถึง 28 กุมภาพันธ์ พ.ศ. 2569
2. เป็นใบสั่งยาที่มีรายการยาตั้งแต่ 5 รายการขึ้นไป ซึ่งจัดอยู่ในกลุ่มใบสั่งยาที่มีความเสี่ยงสูงตามนิยามของภาวะการใช้ยาหลายชนิดร่วมกัน (Polypharmacy)

เกณฑ์การคัดออก

1. เป็นใบสั่งยาที่เกิดจากข้อผิดพลาดของระบบสารสนเทศ เช่น ความผิดพลาดของระบบเครือข่าย การทำงานผิดพลาดของโปรแกรม หรือการบันทึกข้อมูลซ้ำซ้อน
2. เป็นใบสั่งยาที่มีข้อมูลไม่ครบถ้วน เช่น ขาดข้อมูลสำคัญของผู้ป่วย ข้อมูลรายการยาไม่สมบูรณ์ หรือไม่มีข้อมูลผลลัพธ์การวิเคราะห์จากระบบ AI

ผู้เข้าร่วมการทดลอง

ผู้เข้าร่วมการทดลอง คือ เกสัชกรวิชาชีพที่ปฏิบัติงานในโรงพยาบาลกรุงเทพขอนแก่น และมีประสบการณ์ในการตรวจสอบใบสั่งยาและการประเมินความคลาดเคลื่อนทางยา โดยเกสัชกรจะทำหน้าที่ตรวจสอบผลลัพธ์ที่ได้จากระบบ AI และใช้เป็นข้อมูลอ้างอิง (reference standard) สำหรับการประเมินความถูกต้องของระบบ

เครื่องมือที่ใช้ในการเก็บรวบรวมข้อมูล

เครื่องมือที่ใช้ในการวิจัยประกอบด้วย

1. Knowledge-Based Generative AI System (KBGI)

ระบบปัญญาประดิษฐ์ที่พัฒนาขึ้นเพื่อใช้ในการวิเคราะห์และจำแนกประเภทใบสั่งยา โดยผสมผสานความสามารถของ Generative AI ในการประมวลผลข้อความเข้ากับฐานความรู้ทางคลินิกด้านเภสัชกรรม เพื่อช่วยตรวจจับและจำแนกความคลาดเคลื่อนทางยา

2. Electronic Health Records (EHRs)

ข้อมูลจากระบบเวชระเบียนอิเล็กทรอนิกส์ของโรงพยาบาล ใช้เป็นแหล่งข้อมูลสำหรับการทดสอบและประเมินประสิทธิภาพของระบบ AI

การสร้างเครื่องมือที่ใช้ในการเก็บรวบรวมข้อมูล

การสร้างเครื่องมือสำหรับการวิจัยแบ่งออกเป็นสองส่วนหลัก ได้แก่

1. การพัฒนา Knowledge-Based Generative AI System (KBGI)
2. การพัฒนาโปรแกรมวิเคราะห์ผลลัพธ์ด้วยภาษา Python

1. การพัฒนา Knowledge-Based Generative AI System (KBGI)

การพัฒนา Knowledge-Based Generative AI System (KBGI) ในงานวิจัยนี้มีวัตถุประสงค์เพื่อสร้างระบบปัญญาประดิษฐ์ที่สามารถวิเคราะห์ข้อมูลใบสั่งยา เชื่อมโยงข้อมูลกับองค์ความรู้ทางคลินิก และจำแนกประเภทความคลาดเคลื่อนทาง

ยาในลักษณะ Multi-label Classification โดยอาศัยแนวคิดของ Knowledge-Based Generative AI ซึ่งผสมผสานความสามารถของโมเดลภาษาขนาดใหญ่ (Large Language Models) กับฐานความรู้ทางการแพทย์และเภสัชกรรมที่ผ่านการตรวจสอบแล้ว

การพัฒนาระบบ KBGI ประกอบด้วยขั้นตอนสำคัญ ได้แก่ การรวบรวมฐานความรู้ การออกแบบระบบปัญญาประดิษฐ์ และการทดสอบระบบก่อนนำไปใช้ในการวิเคราะห์ข้อมูลจริง

1.1 การรวบรวมฐานความรู้ (Knowledge Base Construction)

ขั้นตอนแรกของการพัฒนาระบบ KBGI คือการรวบรวมและจัดระเบียบองค์ความรู้ทางคลินิกที่เกี่ยวข้องกับ **ความปลอดภัยทางยา (Medication Safety)** และ **ความคลาดเคลื่อนในการสั่งจ่ายยา (Medication Errors)** เพื่อใช้เป็นฐานความรู้สำหรับการวิเคราะห์ของระบบ AI

องค์ความรู้ที่นำมาใช้ประกอบด้วย

- คำจำกัดความและการจำแนกประเภทของความคลาดเคลื่อนทางยา
- แนวทางการใช้ยาอย่างเหมาะสมตามหลักฐานเชิงวิชาการ
- ข้อมูลปฏิกิริยาระหว่างยา (Drug–Drug Interactions)
- หลักการปรับขนาดยาตามลักษณะผู้ป่วย เช่น อายุ น้ำหนัก การทำงานของอวัยวะ และภาวะโรคร่วม
- ข้อมูลข้อบ่งใช้ ข้อห้ามใช้ และข้อควรระวังในการใช้ยา

แหล่งข้อมูลที่ใช้ในการสร้างฐานความรู้ประกอบด้วย

- ฐานข้อมูลทางการแพทย์ที่ได้รับการยอมรับในระดับสากล เช่น UpToDate และ Medscape
- ข้อมูลจาก ระบบเวชระเบียนอิเล็กทรอนิกส์ (Electronic Health Records: EHRs) ของโรงพยาบาล
- วารสารการวิชาการและงานวิจัยด้านเภสัชกรรมคลินิกและความปลอดภัยทางยา

ข้อมูลจากแหล่งดังกล่าวถูกนำมาจัดโครงสร้างให้อยู่ในรูปแบบที่ระบบ AI สามารถนำไปใช้ในการให้เหตุผลเชิงคลินิกได้ เช่น การจัดหมวดหมู่ข้อมูลยา ความสัมพันธ์ระหว่างยาและโรค และเงื่อนไขทางคลินิกที่เกี่ยวข้องกับการใช้ยาอย่างปลอดภัย

1.2 การออกแบบระบบปัญญาประดิษฐ์ (AI System Design)

ระบบ KBGI ถูกพัฒนามาบนพื้นฐานของโมเดล ChatGPT Assistant ซึ่งเป็นโมเดลภาษาขนาดใหญ่ที่สามารถประมวลผลข้อความ วิเคราะห์บริบท และสร้างคำตอบเชิงเหตุผลจากข้อมูลที่ได้รับ

แนวคิดหลักที่ใช้ในการออกแบบระบบคือ Knowledge-Based Generative AI ซึ่งเป็นการผสานระหว่าง

- ความสามารถของ Generative AI ในการประมวลผลภาษาและข้อมูลที่ไม่เป็นโครงสร้าง
- ฐานความรู้ทางคลินิกและเภสัชกรรมที่ใช้กับการให้เหตุผลของระบบ

โครงสร้างของระบบประกอบด้วยองค์ประกอบสำคัญ ได้แก่

- **Knowledge Base**

ฐานข้อมูลองค์ความรู้ทางคลินิกและเภสัชกรรมที่รวบรวมจากแหล่งข้อมูลที่เชื่อถือได้

- **Generative AI Engine**

โมเดล ChatGPT Assistant ที่ใช้ในการประมวลผลข้อมูลใบสั่งยา วิเคราะห์บริบททางคลินิก และสร้างผลลัพธ์การจำแนก

- **Prompt Structure และ Data Interface**

กลไกสำหรับจัดรูปแบบข้อมูลผู้ป่วย ข้อมูลการวินิจฉัยโรค และรายการยา เพื่อส่งเข้าสู่ระบบ AI อย่างเป็นระบบ

- **Response Output Module**

ส่วนที่ใช้จัดรูปแบบผลลัพธ์ของ AI ในรูปแบบข้อความ ซึ่งระบุประเภทของความคลาดเคลื่อนทางยาและคำอธิบายที่เกี่ยวข้อง

ระบบถูกออกแบบให้สามารถดำเนินการดังต่อไปนี้

- วิเคราะห์ข้อมูลใบสั่งยาที่ได้รับจากระบบเวชระเบียนอิเล็กทรอนิกส์
- เชื่อมโยงข้อมูลทางคลินิกกับฐานความรู้ด้านเภสัชกรรม
- ตรวจสอบความเสี่ยงของความคลาดเคลื่อนทางยา
- จำแนกประเภทความคลาดเคลื่อนทางยาในลักษณะ Multi-label Classification เนื่องจากใบสั่งยา 1 ฉบับอาจมีข้อผิดพลาดมากกว่าหนึ่งประเภท

1.3 การทดสอบระบบ (System Testing)

หลังจากพัฒนาระบบ KBGI แล้ว ได้ดำเนินการทดสอบระบบในสภาพแวดล้อมการทดลอง เพื่อประเมินความสามารถของระบบก่อนนำไปใช้วิเคราะห์ข้อมูลจริง การทดสอบระบบมีวัตถุประสงค์เพื่อประเมินความสามารถของระบบในด้านต่อไปนี้

- ความสามารถในการ วิเคราะห์ข้อมูลใบสั่งยาและข้อมูลผู้ป่วย
- ความสามารถในการ ตรวจสอบความเสี่ยงของความคลาดเคลื่อนทางยา

- ความสามารถในการ จำแนกประเภทข้อผิดพลาดในการสั่งจ่ายยา

การทดสอบดังกล่าวช่วยตรวจสอบว่าระบบสามารถประมวลผลข้อมูลทางคลินิกได้อย่างถูกต้อง และให้ผลลัพธ์ที่สอดคล้องกับหลักการด้านความปลอดภัยทางยา ก่อนนำระบบไปใช้ในขั้นตอนการวิเคราะห์ข้อมูลใบสั่งยาจริงในงานวิจัย

2. การพัฒนาโปรแกรมวิเคราะห์ผลลัพธ์ด้วยภาษา Python

ในการวิจัยครั้งนี้ ได้พัฒนาโปรแกรมด้วยภาษา Python เพื่อใช้เป็นเครื่องมือหลักในการจัดการข้อมูล วิเคราะห์ผลลัพธ์จากระบบ Knowledge-Based Generative AI และประเมินประสิทธิภาพของการจำแนกประเภทใบสั่งยาแบบหลายป้ายกำกับ (Multi-label Classification) โดยเลือกใช้ภาษา Python เนื่องจากเป็นภาษาที่ได้รับความนิยมอย่างกว้างขวางในงานด้านวิทยาการข้อมูล ปัญญาประดิษฐ์ และชีวสารสนเทศทางการแพทย์ อีกทั้งยังมีไลบรารีที่รองรับการจัดการข้อมูล การวิเคราะห์ทางสถิติ การสร้างแบบจำลองการจำแนกประเภท และการเชื่อมต่อกับบริการปัญญาประดิษฐ์ผ่าน API ได้อย่างมีประสิทธิภาพ

โปรแกรมที่พัฒนาขึ้นมีหน้าที่หลัก 3 ส่วน ได้แก่

1. การเตรียมและทำความสะอาดข้อมูลใบสั่งยา
2. การรับและจัดรูปแบบผลลัพธ์จากระบบ KBGI เพื่อนำมาวิเคราะห์ในรอบของ multi-label classification
3. การคำนวณค่าตัวชี้วัดทางสถิติและการสร้างรายงานผลการประเมินโมเดล

1. การจัดการและทำความสะอาดข้อมูล (Data Cleaning)

ในขั้นตอนการเตรียมข้อมูล ใช้ไลบรารี pandas เป็นเครื่องมือหลักสำหรับการนำเข้าข้อมูลจากไฟล์หรือฐานข้อมูลในรูปแบบตาราง การตรวจสอบความครบถ้วนของข้อมูล การจัดการข้อมูลสูญหาย (missing values) การลบข้อมูลซ้ำซ้อน และการแปลงชนิดข้อมูลให้เหมาะสมต่อการวิเคราะห์ เช่น การแปลงข้อมูลเชิงตัวเลข การจัดรูปแบบชื่อยา และการมาตรฐานค่าที่ใช้ในเวชระเบียนอิเล็กทรอนิกส์ เพื่อให้ข้อมูลมีความพร้อมก่อนเข้าสู่กระบวนการวิเคราะห์และการส่งต่อไปยังระบบ AI โดย pandas ถูกออกแบบมาเพื่อรองรับงานทำความสะอาดข้อมูล การแปลงข้อมูล และการวิเคราะห์ข้อมูลเชิงตารางอย่างมีประสิทธิภาพ

นอกจากนั้น กระบวนการ data cleaning ยังรวมถึงการตรวจสอบความถูกต้องของฟิลด์ที่เกี่ยวข้องกับการวิเคราะห์ทางคลินิก เช่น อายุ น้ำหนัก ส่วนสูง ดัชนีมวลกาย พื้นที่ผิวร่างกาย ข้อมูลการวินิจฉัยโรค และรายการยา เพื่อป้องกันไม่ให้ค่าที่ผิดปกติหรือข้อมูลที่ไม่สมบูรณ์ส่งผลกระทบต่อผลลัพธ์ของระบบ KBGI ในขั้นตอนถัดไป

2. การเตรียมข้อมูลสำหรับการจำแนกแบบหลายป้ายกำกับ (Multi-label Classification)

เนื่องจากใบสั่งยา 1 ฉบับอาจมีความคลาดเคลื่อนมากกว่าหนึ่งประเภทพร้อมกัน การวิเคราะห์จึงอยู่ในกรอบของ multi-label classification ไม่ใช่การจำแนกแบบ binary หรือ multiclass เพียงอย่างเดียว ในขั้นตอนนี้ ใช้ไลบรารีจาก scikit-learn เพื่อแปลงป้ายกำกับของความคลาดเคลื่อนให้อยู่ในรูปแบบที่เหมาะสมสำหรับการประเมินผล เช่น การใช้ MultiLabelBinarizer เพื่อแปลงข้อมูลป้ายกำกับจากรายการข้อความให้เป็นเมทริกซ์แบบไบนารีระดับตัวอย่างต่อฉลาก ซึ่งเป็นรูปแบบมาตรฐานของงาน multi-label learning

สำหรับการคำนวณผลการจำแนก ใช้ฟังก์ชันในหมวด sklearn.metrics เพื่อประเมินค่า Precision, Recall, F1-score และรายงานผลในลักษณะที่รองรับงาน multi-label โดยเฉพาะ ซึ่งสามารถสรุปผลได้ทั้งในระดับรายฉลากและระดับรวมของโมเดล เช่น micro average, macro average และ sample average ทั้งนี้ ในระบบของ scikit-learn มีการระบุชัดเจนว่า metric บางชนิด เช่น subset accuracy และ sample average มีความสำคัญโดยตรงต่อปัญหา multi-label classification (scikit-learn developers, 2026)

3. การสร้าง data pipeline สำหรับส่งข้อมูลเข้าสู่ ChatGPT / KBGI

โปรแกรม Python ถูกออกแบบให้มี data pipeline สำหรับรับข้อมูลใบสั่งยาที่ผ่านการทำความสะอาดแล้ว และจัดรูปแบบข้อมูลให้อยู่ในรูปแบบข้อความเชิงโครงสร้าง (structured prompt text) ก่อนส่งเข้าสู่ระบบ KBGI ซึ่งพัฒนามบนพื้นฐานของ ChatGPT Assistant โดยข้อมูลที่ส่งเข้าสู่ระบบประกอบด้วยข้อมูลผู้ป่วย ข้อมูลการวินิจฉัยโรค และรายละเอียดรายการยา เพื่อให้โมเดลสามารถวิเคราะห์ในบริบททางคลินิกได้ครบถ้วน

กระบวนการนี้ประกอบด้วยขั้นตอนการ map ชื่อฟิล์มทางคลินิก การรวมข้อมูลหลายแหล่งให้อยู่ในลำดับเดียวกัน การสร้างข้อความ prompt ตามโครงสร้างที่กำหนด และการบันทึก input-output log สำหรับการตรวจสอบย้อนหลังและการทำซ้ำของการวิเคราะห์ ทั้งนี้ OpenAI ระบุว่า Responses API เป็นอินเทอร์เฟซหลักสำหรับการสร้างผลลัพธ์จากโมเดล โดยรองรับการส่งข้อความเข้าโมเดลและการจัดการ interaction ในระดับโปรแกรมได้โดยตรง

4. การเชื่อมต่อ API และการจัดการผลลัพธ์จากโมเดล

ในขั้นตอนการเชื่อมต่อกับระบบ AI โปรแกรม Python ทำหน้าที่เป็นตัวกลางในการส่งคำขอ (request) ไปยัง API และรับคำตอบ (response) กลับมาเพื่อนำไปวิเคราะห์ต่อ โดยในระดับการออกแบบโปรแกรม จำเป็นต้องมียุทธศาสตร์ประกอบสำคัญ ได้แก่ การตั้งค่าคีย์ API การจัดการ timeout การตรวจสอบสถานะการตอบกลับ การจัดการข้อผิดพลาดจากการเชื่อมต่อ และการบันทึกผลลัพธ์อย่างเป็นระบบเพื่อใช้ในการประเมินโมเดลภายหลัง

ผลลัพธ์ที่ได้จาก KBGI ถูกออกแบบให้อยู่ในรูปแบบข้อความ จากนั้นโปรแกรม Python จะทำหน้าที่แปลงข้อความดังกล่าวให้เป็นรูปแบบที่เหมาะสมต่อการวิเคราะห์เชิงสถิติ เช่น การสกัดป้ายกำกับความคลาดเคลื่อน การแปลงเป็นรหัสมาตรฐาน และการจัดเก็บในรูปแบบตารางเพื่อเปรียบเทียบกับผลการประเมินโดยเภสัชกร

5. การคำนวณตัวชี้วัดทางสถิติและการสร้างรายงานผล

หลังจากได้ผลการจำแนกจากระบบ AI โปรแกรม Python จะถูกใช้ในการเปรียบเทียบผลลัพธ์กับข้อมูลอ้างอิงจากเภสัชกร และคำนวณตัวชี้วัดทางสถิติที่เกี่ยวข้องกับ multi-label classification ได้แก่ Precision, Recall, F1-score และสถิติความสอดคล้อง เช่น Cohen's Kappa รวมถึงการวิเคราะห์ ROC Curve และค่า AUC ในกรณีที่การประเมินรองรับการตีความในระดับ binary per label การคำนวณเหล่านี้ดำเนินการโดยอาศัยฟังก์ชันมาตรฐานในไลบรารี scikit-learn ซึ่งรองรับทั้งงาน multiclass และ multilabel อย่างเป็นระบบ

นอกจากนี้ ยังใช้ไลบรารีสำหรับการสร้างกราฟและรายงานผล เช่น matplotlib เพื่อแสดงผลในรูปแบบกราฟ ROC, confusion patterns, หรือสรุปค่าประสิทธิภาพของโมเดลในรูปแบบภาพ ซึ่งช่วยให้การตีความผลการวิจัยมีความชัดเจนและสามารถนำเสนอผลได้อย่างเป็นระบบ

6. สภาพแวดล้อมในการพัฒนาและรันโปรแกรม (Execution Environment)

เพื่อให้การพัฒนาโปรแกรมเป็นระบบและสามารถทำซ้ำได้ โปรแกรมทั้งหมดถูกพัฒนาและรันภายใต้ virtual environment ของ Python โดยใช้โมดูล venv เพื่อแยกสภาพแวดล้อมของแพ็คเกจที่ใช้ในงานวิจัยออกจากแพ็คเกจหลักของระบบปฏิบัติการ วิธีการดังกล่าวช่วยลดปัญหาความขัดแย้งของเวอร์ชันไลบรารี และเพิ่มความสามารถในการทำซ้ำของงานวิจัยในอนาคต

การเก็บรวบรวมข้อมูล

ขั้นตอนการเก็บข้อมูลมีดังนี้

1. เจ้าหน้าที่ฝ่ายเทคโนโลยีสารสนเทศของโรงพยาบาลดึงข้อมูลใบสั่งยาจากระบบ HIS ตามเกณฑ์การคัดเลือกที่กำหนด

2. เจ้าหน้าที่ทำการปกปิดข้อมูลส่วนบุคคลของผู้ป่วย เช่น ชื่อ นามสกุล HN หมายเลขคำสั่งยา และ Visit Number เพื่อป้องกันการระบุตัวตน
3. ผู้วิจัยนำข้อมูลที่ได้เข้าสู่ระบบ KBGI เพื่อทำการวิเคราะห์และจำแนกประเภทใบสั่งยา

ข้อมูลที่ใช้ในการวิเคราะห์

ข้อมูลผู้ป่วย

- น้ำหนัก
- ส่วนสูง
- อายุ
- ความดันโลหิต (SBP/DBP)
- ดัชนีมวลกาย (BMI)
- พื้นที่ผิวร่างกาย (BSA)
- ประวัติการแพ้ยาและอาหาร
- การวินิจฉัยโรคตามรหัส ICD

ข้อมูลใบสั่งยา

- ชื่อยา
- ขนาดยาและวิธีการใช้ยา
- จำนวนเม็ดหรือระยะเวลาการใช้ยา
- สถานะของยา เช่น Dispensed หรือ Cancelled

ผลลัพธ์จากระบบ AI

ระบบ KBGI จะส่งผลลัพธ์กลับมาในรูปแบบข้อความ (Text Response) ซึ่งระบุการจำแนกประเภทของใบสั่งยาและความเสี่ยงของความคลาดเคลื่อนทางยา

การวิเคราะห์ข้อมูลและสถิติที่ใช้ในการวิเคราะห์ข้อมูล

การวิเคราะห์ข้อมูลดำเนินการตามตอนขั้นตอนดังนี้

1. การประเมินประสิทธิภาพของโมเดล AI (AI Model Performance Evaluation) โดย Metrics ที่ใช้สำหรับวัดประสิทธิภาพการจำแนกประเภท (Classification Performance) ของ knowledge was generative AI ที่พัฒนาขึ้น มีดังนี้

- 1.1. **Precision (Positive Predictive Value - PPV)** วัดเปอร์เซ็นต์ของการจำแนกที่ถูกต้อง
- 1.2. **Recall (Sensitivity)** วัดความสามารถในการตรวจจับข้อผิดพลาดทั้งหมด
- 1.3. **F1-Score** ค่ากลางระหว่าง Precision และ Recall

สูตรที่ใช้คำนวณ

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN}$$

$$\text{Precision} = \frac{TP}{TP + FP}$$

$$\text{Recall (Sensitivity)} = \frac{TP}{TP + FN}$$

$$\text{F1-Score} = 2 \times \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}}$$

- **TP (True Positive):** ระบบ AI จำแนกข้อผิดพลาดในการส่งจ่ายยาถูกต้อง
 - **TN (True Negative):** ระบบ AI จำแนกการส่งจ่ายยาที่ถูกต้องถูกต้อง
 - **FP (False Positive):** ระบบ AI จำแนกการส่งจ่ายยาที่ถูกต้องเป็นข้อผิดพลาด
 - **FN (False Negative):** ระบบ AI พลาดข้อผิดพลาดที่ควรตรวจพบ
2. การวิเคราะห์ความน่าเชื่อถือของโมเดล AI (AI Reliability)
 - 2.1. Inter-Rater Reliability (IRR) โดยใช้ Cohen's Kappa Score (**K**) วัดความสอดคล้องการระหว่าง AI และเภสัชกร โดยสามารถแปลผลได้ดังนี้
 - **K > 0.80** = มีความสอดคล้องสูง
 - **K 0.60 - 0.79** = มีความสอดคล้องปานกลาง
 - **K < 0.60** = ต้องปรับปรุงโมเดล AI
 - 2.2. Receiver Operating Characteristic (ROC) Curve โดย ROC Curve เป็นกราฟที่ใช้แสดงความสามารถของโมเดล AI ในการแยกแยะระหว่าง Positive class (ข้อผิดพลาดในการส่งจ่ายยา) และ Negative class (การส่งจ่ายยาที่ถูกต้อง) โดยแกนของกราฟมีองค์ประกอบดังนี้
 - แกน X (False Positive Rate, FPR): อัตราการเกิด False Positive (FP)
 - แกน Y (True Positive Rate, TPR หรือ Sensitivity): อัตราการตรวจพบข้อผิดพลาดจริง (TP)

สูตรคำนวณค่าบน ROC Curve

$$\text{True Positive Rate (TPR) หรือ Sensitivity} = \frac{TP}{TP + FN}$$

$$\text{False Positive Rate (FPR)} = \frac{FP}{FP + TN}$$

2.3. Area Under the Curve (AUC)

AUC คือค่าที่ใช้บอกความสามารถของโมเดล AI ในการแยกแยะระหว่างกลุ่ม **Positive** และ **Negative** ยิ่งค่า AUC ใกล้ 1 มากเท่าใด หมายถึงโมเดลสามารถจำแนกได้แม่นยำขึ้น

การคำนวณค่า AUC

$$AUC = \int_0^1 TPR(FPR) d(FPR)$$

โดยค่าพื้นที่ใต้เส้นโค้ง (AUC) คำนวณจาก **Integral** ของ TPR ตาม FPR

- $AUC > 0.90 \rightarrow$ โมเดลแม่นยำมาก
- $AUC 0.80 - 0.89 \rightarrow$ โมเดลมีความแม่นยำดี
- $AUC 0.70 - 0.79 \rightarrow$ โมเดลต้องปรับปรุง
- $AUC < 0.70 \rightarrow$ โมเดลไม่ดี ต้องปรับปรุงอย่างเร่งด่วน

บรรณานุกรม

- Alsulami, Z., Conroy, S., & Choonara, I. (2013). Medication errors in the Middle East countries: A systematic review of the literature. *European Journal of Clinical Pharmacology*, 69(4), 995–1008. <https://doi.org/10.1007/s00228-012-1435-y>
- Amin, D., Garzón-Orjuela, N., Garcia Pereira, A., Parveen, S., Vornhagen, H., & Vellinga, A. (2023). Artificial Intelligence to Improve Antibiotic Prescribing: A Systematic Review. *Antibiotics*, 12(8), 1293. <https://doi.org/10.3390/antibiotics12081293>
- Balestra, M., Chen, J., Iturrate, E., Aphinyanaphongs, Y., & Nov, O. (2021). Predicting inpatient pharmacy order interventions using provider action data. *JAMIA Open*, 4(3), ooab083. <https://doi.org/10.1093/jamiaopen/ooab083>
- Bhatt, A., Roberts, R., Chen, X., Li, T., Connor, S., Hatim, Q., Mikailov, M., Tong, W., & Liu, Z. (2021). DICE: A Drug Indication Classification and Encyclopedia for AI-Based Indication Extraction. *Frontiers in Artificial Intelligence*, 4, 711467. <https://doi.org/10.3389/frai.2021.711467>
- Bishop, C. M. (2006). *Pattern recognition and machine learning*. Springer.
- Chelli, M., Descamps, J., Lavoue, V., Trojani, C., Azar, M., Deckert, M., Raynier, J.-L., Clowez, G., Boileau, P., & Ruetsch-Chelli, C. (2024). Hallucination Rates and Reference Accuracy of ChatGPT and Bard for Systematic Reviews: Comparative Analysis. *Journal of Medical Internet Research*, 26, e53164. <https://doi.org/10.2196/53164>
- Corny, J., Rajkumar, A., Martin, O., Dode, X., Lajonchere, J.-P., Billuart, O., Bezie, Y., & Buronfosse, A. (2020). A machine learning-based clinical decision support system to identify prescriptions with a high risk of medication error. *Journal of the American Medical Informatics Association*, 27(11), 1688–1694. <https://doi.org/10.1093/jamia/ocaa154>
- Coulet, A., Shah, N. H., Wack, M., Chawki, M. B., Jay, N., & Dumontier, M. (2018). Predicting the need for a reduced drug dose, at first prescription. *Scientific Reports*, 8(1), 15558. <https://doi.org/10.1038/s41598-018-33980-0>
- Crossnohere, N. L., Elsaid, M., Paskett, J., Bose-Brill, S., & Bridges, J. F. P. (2022). Guidelines for Artificial Intelligence in Medicine: Literature Review and Content Analysis of Frameworks. *Journal of Medical Internet Research*, 24(8), e36823. <https://doi.org/10.2196/36823>
- Gatto, E. C., Ferrandin, M., & Cerri, R. (2025). Multi-label classification with label clusters. *Knowledge and Information Systems*, 67(2), 1741–1785. <https://doi.org/10.1007/s10115-024-02270-9>
- Gonzaga De Andrade Santos, T. N., Mendonça Da Cruz Macieira, G., Cardoso Sodre Alves, B. M., Onozato, T., Cunha Cardoso, G., Ferreira Nascimento, M. T., Saquete Martins-Filho, P. R., Pereira De Lyra, D.,

- & Oliveira Filho, A. D. D. (2020). Prevalence of clinically manifested drug interactions in hospitalized patients: A systematic review and meta-analysis. *PLOS ONE*, 15(7), e0235353. <https://doi.org/10.1371/journal.pone.0235353>
- Härkänen, M., Haatainen, K., Vehviläinen-Julkunen, K., & Miettinen, M. (2021). Artificial Intelligence for Identifying the Prevention of Medication Incidents Causing Serious or Moderate Harm: An Analysis Using Incident Reporters' Views. *International Journal of Environmental Research and Public Health*, 18(17), 9206. <https://doi.org/10.3390/ijerph18179206>
- Heaton, J. (2018). Ian Goodfellow, Yoshua Bengio, and Aaron Courville: Deep learning: The MIT Press, 2016, 800 pp, ISBN: 0262035618. *Genetic Programming and Evolvable Machines*, 19(1–2), 305–307. <https://doi.org/10.1007/s10710-017-9314-z>
- Iancu, A., Leb, I., Prokosch, H.-U., & Rödle, W. (2023). Machine learning in medication prescription: A systematic review. *International Journal of Medical Informatics*, 180, 105241. <https://doi.org/10.1016/j.ijmedinf.2023.105241>
- Klumpp, M., Hintze, M., Immonen, M., Rodenas-Rigla, F., Pilati, F., Aparicio-Martinez, F., Çelebi, D., Liebig, T., Jirstrand, M., Urbann, O., Hedman, M., Lipponen, J. A., Biciato, S., Radan, A.-P., Valdivieso, B., Thronicke, W., Gunopulos, D., & Delgado-Gonzalo, R. (2021). Artificial Intelligence for Hospital Health Care: Application Cases and Answers to Challenges in European Hospitals. *Healthcare*, 9(8), 961. <https://doi.org/10.3390/healthcare9080961>
- Kuperman, G. J., Bobb, A., Payne, T. H., Avery, A. J., Gandhi, T. K., Burns, G., Classen, D. C., & Bates, D. W. (2007). Medication-related Clinical Decision Support in Computerized Provider Order Entry Systems: A Review. *Journal of the American Medical Informatics Association*, 14(1), 29–40. <https://doi.org/10.1197/jamia.M2170>
- Lan, Y., He, S., Liu, K., Zeng, X., Liu, S., & Zhao, J. (2021). Path-based knowledge reasoning with textual semantic information for medical knowledge graph completion. *BMC Medical Informatics and Decision Making*, 21(S9), 335. <https://doi.org/10.1186/s12911-021-01622-7>
- Liu, S., Kawamoto, K., Del Fiol, G., Weir, C., Malone, D. C., Reese, T. J., Morgan, K., ElHalt, D., & Abdelrahman, S. (2022). The potential for leveraging machine learning to filter medication alerts. *Journal of the American Medical Informatics Association : JAMIA*, 29(5), 891–899. <https://doi.org/10.1093/jamia/ocab292>
- Luo, H., Yin, W., Wang, J., Zhang, G., Liang, W., Luo, J., & Yan, C. (2024). Drug-drug interactions prediction based on deep learning and knowledge graph: A review. *iScience*, 27(3), 109148. <https://doi.org/10.1016/j.isci.2024.109148>
- Lyu, K., Tian, Y., Shang, Y., Zhou, T., Yang, Z., Liu, Q., Yao, X., Zhang, P., Chen, J., & Li, J. (2023). Causal

- knowledge graph construction and evaluation for clinical decision support of diabetic nephropathy. *Journal of Biomedical Informatics*, 139, 104298.
<https://doi.org/10.1016/j.jbi.2023.104298>
- Mahomedradja, R. F., Schinkel, M., Sigaloff, K. C. E., Reumerman, M. O., Otten, R. H. J., Tichelaar, J., & Van Agtmael, M. A. (2023). Factors influencing in-hospital prescribing errors: A systematic review. *British Journal of Clinical Pharmacology*, 89(6), 1724–1735. <https://doi.org/10.1111/bcp.15694>
- Mesko, B., & Topol, E. J. (2023a). The imperative for regulatory oversight of large language models (or generative AI) in healthcare. *Npj Digital Medicine*, 6(1), 120.
<https://doi.org/10.1038/s41746-023-00873-0>
- Mesko, B., & Topol, E. J. (2023b). The imperative for regulatory oversight of large language models (or generative AI) in healthcare. *Npj Digital Medicine*, 6(1), 120.
<https://doi.org/10.1038/s41746-023-00873-0>
- Natsiavas, P., Malousi, A., Bousquet, C., Jaulent, M.-C., & Koutkias, V. (2019). Computational Advances in Drug Safety: Systematic and Mapping Review of Knowledge Engineering Based Approaches. *Frontiers in Pharmacology*, 10, 415. <https://doi.org/10.3389/fphar.2019.00415>
- Noorbakhsh-Sabet, N., Zand, R., Zhang, Y., & Abedi, V. (2019). Artificial Intelligence Transforms the Future of Health Care. *The American Journal of Medicine*, 132(7), 795–801.
<https://doi.org/10.1016/j.amjmed.2019.01.017>
- Patel, J., Ladani, A., Sambamoorthi, N., LeMasters, T., Dwibedi, N., & Sambamoorthi, U. (2020). A Machine Learning Approach to Identify Predictors of Potentially Inappropriate Non-Steroidal Anti-Inflammatory Drugs (NSAIDs) Use in Older Adults with Osteoarthritis. *International Journal of Environmental Research and Public Health*, 18(1), 155. <https://doi.org/10.3390/ijerph18010155>
- Poly, T. N., Islam, M. M., Muhtar, M. S., Yang, H.-C., Nguyen, P. A. A., & Li, Y.-C. J. (2020). Machine Learning Approach to Reduce Alert Fatigue Using a Disease Medication-Related Clinical Decision Support System: Model Development and Validation. *JMIR Medical Informatics*, 8(11), e19489.
<https://doi.org/10.2196/19489>
- Rajkomar, A., Dean, J., & Kohane, I. (2019). Machine Learning in Medicine. *New England Journal of Medicine*, 380(14), 1347–1358. <https://doi.org/10.1056/NEJMra1814259>
- Ranchon, F., Chanoine, S., Lambert-Lacroix, S., Bosson, J.-L., Moreau-Gaudry, A., & Bedouch, P. (2023). Development of artificial intelligence powered apps and tools for clinical pharmacy services: A systematic review. *International Journal of Medical Informatics*, 172, 104983.
<https://doi.org/10.1016/j.ijmedinf.2022.104983>

- Singh, B., Olds, T., Brinsley, J., Dumuid, D., Virgara, R., Matricciani, L., Watson, A., Szeto, K., Eglitis, E., Miatke, A., Simpson, C. E. M., Vandelanotte, C., & Maher, C. (2023). Systematic review and meta-analysis of the effectiveness of chatbots on lifestyle behaviours. *Npj Digital Medicine*, 6(1), 118. <https://doi.org/10.1038/s41746-023-00856-1>
- Soroush, A., Glicksberg, B. S., Zimlichman, E., Barash, Y., Freeman, R., Charney, A. W., Nadkarni, G. N., & Klang, E. (2024). Large Language Models Are Poor Medical Coders—Benchmarking of Medical Code Querying. *NEJM AI*, 1(5). <https://doi.org/10.1056/Aldbp2300040>
- Sutton, R. T., Pincock, D., Baumgart, D. C., Sadowski, D. C., Fedorak, R. N., & Kroeker, K. I. (2020). An overview of clinical decision support systems: Benefits, risks, and strategies for success. *Npj Digital Medicine*, 3(1), 17. <https://doi.org/10.1038/s41746-020-0221-y>
- The Lancet Digital Health. (2023). ChatGPT: Friend or foe? *The Lancet Digital Health*, 5(3), e102. [https://doi.org/10.1016/S2589-7500\(23\)00023-7](https://doi.org/10.1016/S2589-7500(23)00023-7)
- Topol, E. J. (2019). High-performance medicine: The convergence of human and artificial intelligence. *Nature Medicine*, 25(1), 44–56. <https://doi.org/10.1038/s41591-018-0300-7>
- Tsoumakas, G., & Katakis, I. (n.d.). *Multi-Label Classification: An Overview*.
- Zhang, M.-L., & Zhou, Z.-H. (2014). A Review on Multi-Label Learning Algorithms. *IEEE Transactions on Knowledge and Data Engineering*, 26(8), 1819–1837. <https://doi.org/10.1109/TKDE.2013.39>